

Identificación de dispositivos IoT a través de huellas hardware

Autor:

Sergio MARÍN SÁNCHEZ

Tutores:

Gregorio MARTÍNEZ

PÉREZ

Pedro Miguel SÁNCHEZ

SÁNCHEZ

UNIVERSIDAD DE
MURCIA

Índice

- 1 Introducción
- 2 Estado del arte
- 3 Diseño
- 4 Experimentos
- 5 Resultados
- 6 Conclusiones y vías futuras




- ▶ Los dispositivos IoT traen consigo numerosos **riesgos de seguridad**.
- ▶ Métodos tradicionales de identificación:
 - ▷ Dirección IP.
 - ▷ Dirección MAC.
 - ▷ Certificados digitales.
- ▶ Limitaciones:
 - ▷ Direcccionamiento dinámico.
 - ▷ Modificaciones del usuario.
 - ▷ Robo de credenciales.



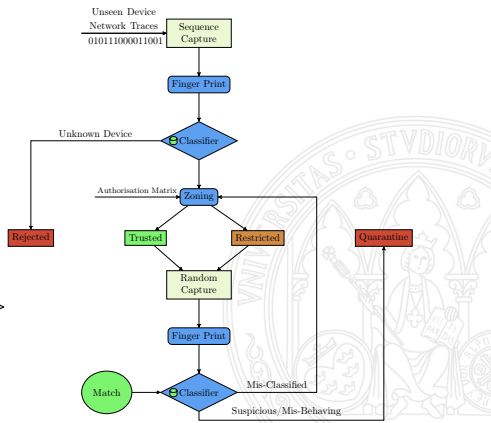
- ▶ Identificación **individual** de los dispositivos.
 - ▷ Mayor seguridad.
- ▶ Diferencias en la **fabricación** de los dispositivos.
 - ▷ Diferentes tiempos en realizar un mismo proceso.
 - ▷ Desviaciones en el reloj interno.
- ▶ Objetivos de este trabajo:
 - ▷ Diseñar una **arquitectura** para este sistema.
 - ▷ Recolectar marcas de tiempo de los dispositivos.
 - ▷ Generar **huellas estadísticas** de los dispositivos.
 - ▷ **Machine Learning** para evaluar el proceso de identificación.

Referencia	Tipo de identificación	Enfoque	Tipo de aprendizaje	Resultados
Pascal Oser et al.	Tipo de dispositivo	Machine Learning	Supervisado	99.76 % de accuracy y 97.03 % de precisión
Salma Hamad et al.	Individual	Machine Learning	Supervisado	89 % de accuracy
Ahmet Aksoy et al.	Tipo y modelo del dispositivo	Machine Learning	Supervisado	Entre 42.2 % y 100 % de accuracy, con un promedio de 82 %
Hossein Jafari et al.	Individual	Machine Learning	Supervisado	96.3 % de accuracy en DNN, 94.7 % de accuracy en CNN y 76 % de accuracy en LSTM
Fabian Lanze et al.	Modelo del dispositivo	Análisis estadístico (regresión lineal)	-	Método no válido para identificar unívocamente un dispositivo.
Yair Meidan et al.	Tipo y modelo	Machine Learning	Supervisado	99.28 % de accuracy
Loh Chin Choong Desmond et al.	Individual	Machine Learning	No supervisado	Entre un 70 % y 80 % de accuracy
Este trabajo	Individual	Machine Learning	Supervisado y No supervisado	99.38 % de Accuracy, 99.39 % de Recall y 99.38 % de f -score

Tabla: Resultados en el estado del arte

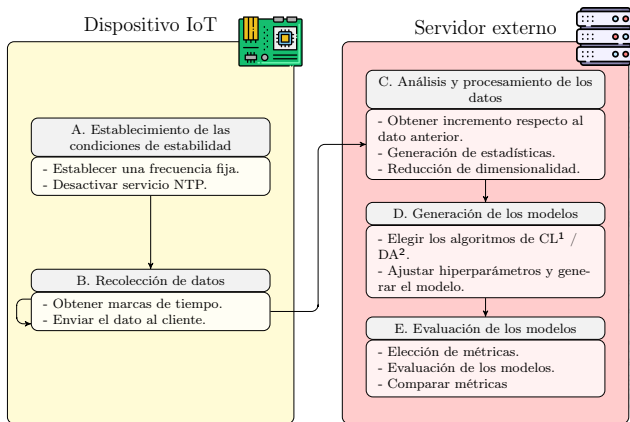


(a) Propuesta de Ahmet Aksoy et al. para identificar **modelos**.



(b) Propuesta de Salma Hamad et al. para identificar **dispositivos**.

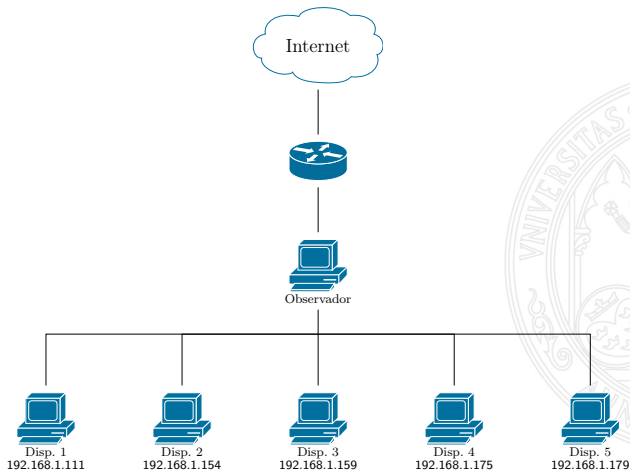
► Arquitectura propuesta.



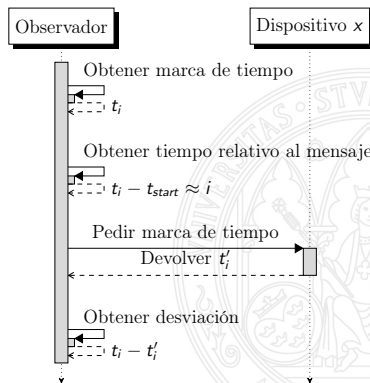
1: Clasificación

2: Detección de anomalías

► Topología de la red.



- La marca de tiempo relativa a cada mensaje desde el inicio, $t_i - t_{start}$.
- La marca de tiempo absoluta del observador t_i .
- La marca de tiempo absoluta del dispositivo t'_i .
- La desviación del reloj del dispositivo respecto al del observador, $t_i - t'_i$.



- Evaluación de los resultados.
 - ▷ Algoritmos de ML supervisados para **clasificación**.
 - ▷ Algoritmos de ML no supervisados para **detección de anomalías**.

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN}$$


$$Recall = \frac{TP}{TP + FN}$$

$$f - score = \frac{2 \cdot TP}{2 \cdot TP + FP + FN}$$


$$TNR = \frac{TN}{TN + FP}$$

time	TSrock	TSrasp	offset	device
292	119238112796030	104592709716803	-14645403079227	192.168.1.111
1001191222	119239113986960	104593710167425	-14645403819535	192.168.1.111
2001485862	119240114281600	104594710453699	-14645403827901	192.168.1.111
⋮	⋮	⋮	⋮	⋮


Tabla: Ejemplo de los datos obtenidos de cada dispositivo




(a) Desviación acumulada muestra secuencial



(b) Desviación acumulada muestra paralela



(a) Desviación muestra secuencial



(b) Desviación muestra paralela

Experimentos

Generación de estadísticas y reducción de la dimensionalidad

	Sum	Mean	Median	Mode	Std	IQR	Kurtosis	Skew	Max	Min	Device
1	-284.0	-4.733333333333333	-203.0	-10750.0	6531.321744049499	8739.5	-0.8026364427898236	0.266444555013173	12077.0	-10750.0	Disp. 1
2	-65895.0	-1098.25	106.5	-13344.0	3926.559099283938	2519.75	1.4605213340303709	-1.1040127142547507	7616.0	-13344.0	Disp. 2
3	96179.0	1602.9833333333333	815.0	-8136.0	5010.092595279735	6575.5	-0.39715065367509084	0.2484646585713819	12831.0	-8136.0	Disp. 3
4	109162.0	1819.3666666666666	2016.5	-10485.0	6159.084454763058	8290.5	-0.7264084617343212	-0.3858981208999922	11469.0	-10485.0	Disp. 4
5	-81317.0	-1355.2833333333333	-2127.0	-6378.0	3665.051390911538	2616.5	2.701193448053943	1.7089231615691112	10383.0	-6378.0	Disp. 5
6	19928.0	332.1333333333333	-147.0	-10750.0	6613.483928825726	10212.0	-0.8404647945245984	0.23473423365399895	12077.0	-10750.0	Disp. 1
:	:	:	:	:	:	:	:	:	:	:	:

Tabla: Datos estadísticos muestra paralela



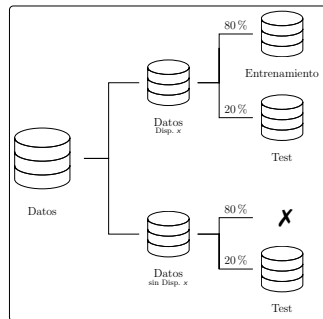


Figura: Correlación entre las variables estadísticas



(a) Particionamiento para clasificadores



(b) Particionamiento para la
detección de anomalías

Resultados

Comparativa de algoritmos




Figura: Algoritmos de clasificación

	Isolation Forest		Local Outlier Factor		OneClass-SVM	
	Recall	TNR	Recall	TNR	Recall	TNR
Disp. 1	95.12 %	10.36 %	98.99 %	10.68 %	49.48 %	58.24 %
Disp. 2	94.98 %	28.87 %	98.45 %	57.74 %	50.90 %	70.36 %
Disp. 3	94.80 %	13.90 %	98.73 %	13.64 %	49.84 %	52.65 %
Disp. 4	95.80 %	16.61 %	98.88 %	8.74 %	50.54 %	64.66 %
Disp. 5	94.89 %	46.99 %	98.63 %	77.98 %	49.53 %	94.59 %


Tabla: Algoritmos de detección de anomalías

Resultados

Resultados finales

Resultados:

- Accuracy: 99.38 %
- f -score: 99.38 %
- Recall: 99.39 %



► Conclusiones:

- ▷ Se ha diseñado un sistema capaz de reconocer dispositivos **individuales**.
- ▷ Los resultados obtenidos son similares a los del estado del arte.
- ▷ Se ha conseguido haciendo uso únicamente de una característica hardware.

► Vías futuras:

- ▷ Extender el sistema fuera de red local.
- ▷ Mecanismos de identificación a **tiempo real**.
 - Generar huellas estadísticas de todos los dispositivos.
 - Actualización a modelos capaz de actualizarse.

Gracias por su atención.
¿Alguna pregunta?

