



UNIVERSIDAD DE MURCIA

TRABAJO FINAL DE GRADO

Identificación de dispositivos IoT a través de huellas hardware

Autor:

Sergio MARÍN SÁNCHEZ
sergio.marins@um.es

Tutores:

Gregorio MARTÍNEZ PÉREZ

gregorio@um.es

Pedro Miguel SÁNCHEZ

SÁNCHEZ

pedromiguel.sanchez@um.es

4 de julio de 2022

*Me gustaría expresar mi
agradecimiento a todos los
amigos, profesores y familia que
han hecho posible que llegue a
este punto.*

Índice general

Declaración firmada sobre la originalidad del trabajo

Resumen	i
Extended abstract	iii
1 Introducción	1
2 Estado del arte	5
2.1 Dispositivos IoT	5
2.1.1 Introducción	5
2.1.2 Arquitectura IoT	5
2.1.3 Aplicaciones del IoT	6
2.2 Machine Learning	7
2.2.1 Introducción	7
2.2.2 Tratamiento de los datos	8
2.2.3 Algoritmos de Machine Learning	8
2.3 Revisión bibliográfica	12
2.3.1 Resultados de la revisión bibliográfica	17
3 Análisis de objetivos y metodología	19
3.1 Análisis de objetivos	19
3.2 Metodología de trabajo	19
4 Diseño y resolución	21
4.1 Arquitectura propuesta	22
4.2 Elección del protocolo	23
4.3 Obtención de datos	23
4.4 Análisis de los datos	24
4.4.1 Experimento 1: Muestra secuencial	25
4.4.2 Experimento 2: Muestra paralela	26
4.4.3 Elección de la muestra de datos	27
4.5 Preprocesamiento de los datos	28
4.5.1 Obtención de las variables estadísticas	28
4.5.2 Reducción de la dimensionalidad	29

4.6	Entrenamiento de los modelos	29
4.6.1	Entrenamiento de los algoritmos de clasificación	30
4.6.2	Entrenamiento de los algoritmos de detección de anomalías	32
5	Resultados	33
6	Conclusiones y vías futuras	37
	Bibliografía	39
	Acrónimos	43

Índice de figuras

2.1	Arquitectura IoT propuesta [51]	6
2.2	Funcionamiento del algoritmo KNN [9]	10
2.3	Separación por hiperplanos SVM [10]	11
2.4	Ejemplo de OneClass-SVM [19]	12
2.5	Ejemplo de Isolation Forest [32]	13
2.6	Desbordamiento del contador [33]	14
2.7	Modelo del sistema de identificación [16]	15
2.8	Clasificador de dos niveles [2]	16
4.1	Topología de la red	21
4.2	Arquitectura propuesta	22
4.3	Offset acumulado muestra secuencial	25
4.4	Diferencias entre offsets de dispositivos	25
4.5	Diagrama de cajas muestra secuencial	26
4.6	Offset acumulado muestra paralela	27
4.7	Diagrama de cajas muestra paralela	27
4.8	Ejemplo de una ventana deslizante	28
4.9	Correlación entre las variables estadísticas	29
4.10	Particiones de los datos	30
4.11	Comparativa hiperparámetros Random Forest	31
4.12	Particiones de los datos	32
5.1	Comparativa de resultados entre modelos de clasificación	34
5.2	Matrices de confusión con datos de la muestra paralela	35
5.3	Matriz de confusión del modelo final	36

Índice de tablas

2.1	Resultados en el estado del arte	18
4.1	Ejemplo de los datos obtenidos de cada dispositivo	24
4.2	Datos estadísticos muestra paralela	29
4.3	Equivalencia entre algoritmo e implementación	30
5.1	Ejemplo de matriz de confusión	33
5.2	Matrices de confusión del Disp. 1 con el modelo de Isolation Forest	34
5.3	Resultados de los modelos de detección de anomalías	36

Declaración firmada sobre la originalidad del trabajo

D. Sergio Marín Sánchez, con DNI 49197868V, estudiante de la titulación de Grado en Ingeniería Informática de la Universidad de Murcia y autor del TF titulado “Identificación de dispositivos IoT a través de huellas hardware”.

De acuerdo con el Reglamento por el que se regulan los Trabajos Fin de Grado y de Fin de Máster en la Universidad de Murcia (aprobado C. de Gob. 30-04-2015, modificado 22-04-2016 y 28-09-2018), así como la normativa interna para la oferta, asignación, elaboración y defensa de los Trabajos Fin de Grado y Fin de Máster de las titulaciones impartidas en la Facultad de Informática de la Universidad de Murcia (aprobada en Junta de Facultad 27-11-2015).

DECLARO:

Que el Trabajo Fin de Grado presentado para su evaluación es original y de elaboración personal. Todas las fuentes utilizadas han sido debidamente citadas. Así mismo, declara que no incumple ningún contrato de confidencialidad, ni viola ningún derecho de propiedad intelectual e industrial.

Murcia, a 4 de julio de 2022

Fdo.: Sergio Marín Sánchez
Autor del TF

Resumen

En este proyecto se ha diseñado una solución capaz de identificar dispositivos conectados en red local en base a las diferencias entre sus relojes internos comparados con un reloj que se fija como referencia. Con esto, ha sido creado un mecanismo que permitirá gestionar de una mejor manera los dispositivos autorizados a realizar ciertas funciones o estar conectados con otros dispositivos de la red.

Este trabajo se puede dividir en cuatro partes. En primer lugar se realiza una fase de diseño de la arquitectura de la solución que se propone. En esta propuesta de solución se identifican las etapas requeridas para llevar a cabo el desarrollo de este proyecto. En la siguiente parte se explica la obtención de los datos, para lo que han sido utilizados 5 dispositivos iguales en hardware y software (Raspberry Pi 4 Model B). De estos dispositivos se obtienen marcas de tiempo cada segundo de dos formas distintas. Por otro lado, se tiene la fase de análisis estadístico de los datos obtenidos, en el que se generan nuevos datos a partir de los previos. Por último, está la fase del desarrollo de un modelo de Machine Learning que sea capaz de automatizar todo el proceso de distinguir los dispositivos partiendo de los datos estadísticos que se han obtenido previamente.

Para obtener los datos se ha hecho uso de una arquitectura cliente-servidor entre los dispositivos a analizar y el dispositivo observador, con el fin de controlar el ritmo de envío de los paquetes. Las capturas se han realizado de dos formas, en secuencial y en paralelo. Secuencialmente hace referencia a que primero se obtienen todas las marcas de tiempo de un dispositivo y posteriormente se analiza el siguiente. Por otro lado, paralelamente hace referencia a que se obtienen marcas de tiempo de todos los dispositivos simultáneamente.

Una vez se tienen todas las marcas de tiempo, se obtienen sus desviaciones respecto al dispositivo que se designó como referencia. De estas desviaciones se obtiene su incremento entre cada dos puntos. Comparando las muestras individual y paralela entre sí mediante gráficos de cajas, se aprecia que los datos de la muestra individual presentan una estructura que no se asemeja tanto a los datos esperados de estos experimentos. Lo esperado sería encontrar la desviación con valores centrados en 0 (lo que se da en ambas muestras) y muy similares entre todos los dispositivos. Es en este último requisito que la muestra individual no se comporta de la forma esperada y, por tanto, a partir de este punto sólo se usarán los datos de la muestra paralela. Estos valores son agrupados mediante una ventana deslizante de 1 minuto, que equivale a 60 paquetes (se toman muestras cada segundo), y de cada uno de estos grupos se obtienen diversas variables estadísticas.

Antes de proceder con la sección dedicada a Machine Learning, se deben eliminar las va-

riables estadísticas que presenten correlación, de esta forma se reduce la cantidad de variables que se usarán para los entrenamientos.

Una vez se tienen las variables estadísticas finales, se analizarán los algoritmos de Machine Learning que han sido escogidos para este trabajo. Los algoritmos que se van a analizar son por una parte de clasificación, como Random Forest, Multi Layer Perceptron (MLP), K Nearest Neighbours (KNN), Naive Bayes, Árboles de decisión y Support Vector Machines (SVM) con kernel lineal; y por otra, de detección de anomalías no supervisados como, Isolation Forest, Local Outlier Factor (LOF) y OneClass-SVM (OC-SVM).

Para comparar los modelos de clasificación entre sí se usará el modelo entrenamiento/-validación/test como forma de dividir los datos. Se entrenarán todos los modelos con el conjunto de entrenamiento y se comprobará su capacidad de generalización con el conjunto de validación. A la hora de entrenar los modelos se comprobarán diferentes parrillas de hiperparámetros para ajustar los modelos lo más posible a los datos de entrenamiento.

A la hora de particionar el conjunto de datos de cara a los entrenamientos de los algoritmos se ha seguido un método propio, con el fin de no perder la correlación temporal que presenta la muestra. Para dividir el conjunto se selecciona una muestra aleatoria de los datos del tamaño deseado, y posteriormente se restablece el orden original de los mismos. De esta forma se consigue reducir el tamaño del conjunto de datos y conservar la correlación temporal de mismos.

Por otra parte, los algoritmos de detección de anomalías han sido entrenados por cada dispositivo, en lugar de todos a la vez. Se ha usado una parte de los datos de cada dispositivo para entrenar el algoritmo, y posteriormente se ha evaluado su rendimiento el resto de los datos de ese dispositivo y con el resto de dispositivos, esto último de forma separada.

Al realizar estos entrenamientos se puede apreciar que los modelos basados en árboles son los mejores, tanto árboles de decisión (95.92 % de Accuracy) como Random Forest (99.22 % de Accuracy). Durante el desarrollo de los entrenamientos de detección de anomalías se ha apreciado que estos no obtienen resultados elevados. Por estos motivos se elige el algoritmo de Random Forest y se procede a entrenarlo con la totalidad de los datos de entrenamiento y los hiperparámetros usados anteriormente.

Como resultado se tiene que este último modelo de Random Forest final obtiene un valor final de Accuracy de 99.38 %, de Recall de 99.39 % y de f -score de 99.38 %. Gracias a este resultado, se ha llegado a la conclusión de que es posible automatizar el proceso de distinguir dispositivos idénticos de forma remota.

Con vistas a futuro, se puede concluir que este trabajo aporta una solución que potencialmente puede ayudar a la lucha contra la ciberdelincuencia, pero se deben resolver algunos inconvenientes. Por un lado, hay servicios que modifican constantemente el reloj del sistema y esto dificulta la tarea de crear una huella para los dispositivos. Por otro lado, y tal vez el más importante, es que esta huella ha de ser creada para cada dispositivo concreto, lo cual es una labor inmensurable.

Extended abstract

Nowadays, the number of devices connected to the internet has increased significantly due to smartphones, IoT devices, autonomous cars, etc. These devices must be always connected to the internet to be able to perform the actions for which they are intended.

These kinds of devices contain and share a lot of information about the people who use them. For this reason, many people try to get this data for purposes that may not be legal. One way to do it would be to pretend that you are the device of the person that you want to access. In order to succeed, it is necessary to change all the identifiers to those that the criminal wants to impersonate. By doing this, people will connect to the criminal's device without being aware of it.

Devices that have the same hardware and software components are not exactly the same, there are some details during the manufacturing process that cannot be copied. Taking advantage of this, a system with the ability to identify those differences was created and as a consequence, between many devices too.

In this work, Internet of Things (IoT) devices were used to perform the objectives. These are devices capable of connecting to the Internet, collecting data and exchanging this data on their own. The concept of IoT devices was proposed by Kevin Ashton in 1999.

These types of devices need a different network architecture than normal devices because of their requirements regarding security and Quality of Service (QoS). Different proposals have been given from multiple research. One of them is the one from Ibrar Yaqoob et al. [51] where they propose a three-layer architecture: application, transport, and sensing.

As mentioned, in this work a system that can identify those details mentioned above was created. Many studies have already researched device identification, but a lot of times they focus on distinguishing devices, but these investigations do not bring the focus to these devices that are identical in both hardware and software.

Most of the read approaches use Machine Learning, specifically supervised learning algorithms, to identify between different devices, and they use this capacity to identify devices for security purposes, for example, giving access to a private network or knowing if an access point may be malicious. The results of the read approaches are situated between 42 % and nearly 100 % of accuracy value.

In this research, to identify different devices, several timestamps were taken from every device under analysis and, after that, their differences from one to the next one were calcu-

lated. These timestamps contain the amount of time since the device was turned on. The small differences that distinguish these devices make that as time goes by, their internal clocks fluctuated. This error accumulated over time and became more noticeable.

To achieve this work's objectives an architecture for how this work is developed was proposed. This architecture can be divided into two parts. On the one hand, there are devices that generate all the data and share it. On the other hand, there is an external device whose purpose is to collect the data received from the other devices, analyse and process it as well as adjust the Machine Learning algorithms that have been used. This external device also evaluates the Machine Learning models that have been trained yet and additionally it compares them too. This architecture performs all the following stages:

- A) **Set up stability conditions.** This stage performs one fundamental thing which is preparing all devices that are going to be tested. The devices' internal clocks have been set to a fixed frequency. In addition, the NTP service has to be disabled.
- B) **Data gathering.** In this stage, every second, each device under analysis generates a timestamp from its internal clock and sends it to the external device. This stage repeats for the established time, which is a period long enough.
- C) **Data analysis and processing.** In this stage, the external device receives all the timestamps from the devices under analysis and it calculates the increase between every two consecutive timestamps. With all these timestamps' increasing values a dataset is built by the external device. Using this dataset, and a sliding window, various statistical values are obtained which are representative of the window in question. Some of these statistical value may be correlated, that's why those which are correlated are going to be removed from the dataset, except one of them which act as a representative value.
- D) **Model generation.** In this stage the different Machine Learning algorithms are selected. In this work supervised learning algorithms for classification are used as well as unsupervised learning anomaly detection algorithms. Once all the algorithms are selected, it is needed to adjust their hyperparameters in order to make the resulting models fit the data of this work in the best possible way.
- E) **Model evaluation.** In this last stage, all the metrics, which are going to be used to compare the different models with each other, are selected. Classification algorithms and anomaly detection algorithms do not use the same metrics to be compared. The resulting metrics are obtained from each trained model and then all these models are compared between them.

The test scenario made for this project consists of six IoT devices connected to a local network. One of them acted as a client and the others acted as servers. Every second the client sent a timestamp request to the servers, and they replied with it. When the client received this timestamp, it saved it as a record: "(time from the start), (client's ignition time), (server's ignition time), (time difference), (server IP)". The client's time was taken as a reference, and the differences were analysed between the other devices and the client.

The first problem appeared at this time. Taking into account that very small differences were analysed, they might have great accuracy of the times. Initially, it was thought that the best option was using the timestamps contained in the headers of the TCP and ICMP

protocols. This idea was discarded since these headers have few bytes and with them, it can only represent times in milliseconds, which does not provide enough information. For this reason, it was decided to use the body section of the packets; to be able to send data of any length. In this case, it will send absolute timestamps in nanoseconds, which will be encoded with 64 bits. Finally, it was chosen the TCP protocol because, in this way, it was not necessary to start a new connection every time a timestamp was sent.

These timestamps were taken in two different ways. On the one hand, a sequential sample was taken in which it was listening for 2 hours (7200 samples) on each device, one after another. This period of time represents a 10 hours sample (36000 samples). On the other hand, a parallel sample of all devices was also carried out, and this one developed 12 hours (with 43200 samples per device). Another issue that arose at this point was that the device's internal clock was altered by other time synchronization processes, such as the NTP protocol. As a result, it was necessary to use an internal clock that changes its value in a linear way. (`steady_clock`). This internal clock contains the number of CPU cycles since the device was switched on.

The next step was set on to the data analysis part. Firstly, the increase in the deviation between each sample of a device was obtained. In those graphs, the median was expected to be approximately 0 and the interquartile range was expected to be very similar on each device. These results were expected since identical devices are being analyzed and they do not suffer from clock skew, at least theoretically.

Looking at both graphs, the one from the sequential sample and the one from the parallel sample, the median was observed to be actually close to 0, however, the interquartile range oscillated much more in the sequential sample. Therefore, from this point on and because of the training of the models that perform the identification process, this sample was not taken into account; the focus was laid on the parallel sample.

Once it was decided which data was going to be used, the statistical values were obtained, and a 1-minute sliding window (60 samples) was used to obtain them. The statistical values that were obtained were: sum, mean, median, mode, standard deviation, interquartile range, kurtosis, skewness, maximum and minimum.

Before training the models, it was checked if there was a correlation between the different statistical values since having correlated data does not provide information. To do that, a correlation matrix between all the statistical variables was generated and those variables that have a high correlation value with another variable were eliminated. In order to train the different models, it was used the `scikit-learn` library for Python, along with utilities such as `numpy` and `pandas`. In this work it was used supervised learning algorithms, such as Decision Trees, Random Forest, Multi Layer Perceptron (MLP), Naive Bayes, K Nearest Neighbours (KNN) and Support Vector Machines (SVM). In addition, it was also used unsupervised learning anomaly detection algorithms, such as Isolation Forest, Local Outlier Factor (LOF) and OneClass-SVM (OC-SVM).

In order to train the different supervised algorithms and obtain the best possible results, their hyperparameters must be set. To make this adjustment, it was used a smaller set of data, but it was representative of the totality of the data since each training costs a considerable amount of time. It was used a training/validation/test model.

The set of all the data will be divided into two, one with 70 % of the data and another with 30 %. The training set will be used to train the final model and the test model will be used to see the generalization capacity of the model.

The process of adjusting an algorithm takes time since each algorithm has to be trained with each combination of hyperparameters that are required for being tested. For this reason, the volume of data was reduced (70 % of the total) and kept only 35 % of it. This subset will also be divided into a 70/30 ratio in order to validate the results of training with data that the model had not seen before.

To make these partitions, random samples were taken, but as the data had temporal correlation, reordering them was needed so that this correlation could be kept and the models were able to recognize it.

To adjust the hyperparameters of an algorithm, an object called grid, which allows specifying all the hyperparameters that were tested, was used. This tool is very useful since it automates the whole process of testing different hyperparameters and allows us to obtain, in a single run, the results of an algorithm with each combination of hyperparameters.

As regards anomaly detection algorithms, another scheme was used. Their hyperparameters were also adjusted similarly to the supervised ones, however, anomaly detection algorithms used only the data from one device to be trained. It was used 80 % of the data from every device to train the algorithm and, after that, the algorithm was evaluated using two different tests, the remaining 20 % of the device data and the 20 % of all the remaining devices' data. Looking at the first test, how capable to detect the current device was shown, and with the second one, it was shown how capable of not making a mistake was the algorithm.

Once all the models had been tested, it could be seen that the ones with the best results were those that are based on trees; both Decision Trees and Random Forest. In particular, Random Forest was the one with the best results, so, this Random Forest algorithm was chosen to be trained as the final model.

Finally, the Random Forest algorithm with its custom hyperparameters and the training set in its completeness was the only one that have to be trained. Once this has been done, its ability to generalize is checked with the test set and it is obtained a final accuracy of 99.38 %, a recall of 99.39 % and an $f - score$ of 99.38 %.

It can be concluded that it is possible to identify theoretically identical devices automatically, but it should be noted that all of this process has been made on a private network. If the same study had been done over the Internet, the result would have been different. This is because even if all the devices were on the same local network and only the observer was out, each timestamp of each device could be routed differently, which would cause measurement errors. A possible solution to this problem would be to take much longer samples in time, since statistically the packets between two devices will be routed most of the time along the same path, leaving those which are not, like outliers.

CAPÍTULO 1

Introducción

En los últimos años el número de dispositivos conectados a internet se ha incrementado en gran medida [25]. Esto se debe al uso de smartphones, tablets y demás dispositivos que requieren de conexión a internet para llevar a cabo la mayoría (o la totalidad) de tareas para las que han sido diseñados. En especial se han desarrollado en gran medida el número de dispositivos del Internet of Things (IoT) que utilizan nuevas tecnologías como el 5G [34].

Cada dispositivo conectado a internet tiene asociados varios identificadores, como la dirección IP o la dirección MAC. Estos identificadores deberían servir para identificar unívocamente a un dispositivo, pero en la práctica no se da esta situación. Las direcciones IP pueden cambiar automáticamente debido al direccionamiento IP dinámico (mediante servidores DHCP), pero también pueden ser modificadas por las propias personas.

Estas modificaciones pueden ser por temas únicamente relacionados con la privacidad o el rendimiento, pero en muchas ocasiones están relacionadas con la ciberdelincuencia. Los delincuentes pueden intentar falsificar sus identificadores con el objetivo de que las personas, buscando conectarse a un servicio legítimo, acaben conectándose a sus equipos maliciosos.

Este tipo de dispositivos a pesar de ser muy usados, carecen de grandes medidas de seguridad y por este motivo se han producido varios ciberataques en este sector [27] [30]. Uno de los principales problemas que presentan es la intrusión en la red de dispositivos IoT de un dispositivo malicioso con el mismo software y hardware que los dispositivos legítimos [4]. Además de acceder a dicha red, puede ser que el dispositivo intente suplantar a uno de los dispositivos legítimos, perpetrando así un ataque de *spoofing* [31] [50]. También cifrar los datos de un equipo (ataque de ransomware), o bien, introducir virus en muchos equipos con el objetivo de realizar ataques Distributed Denegation of Service (DDoS) mediante miles de equipos infectados (ataques de denegación de servicio distribuidos) [18], entre otros.

Debido a esta amenaza, es necesario saber si el equipo con el que se quiere establecer es el correcto o no. En este punto se debe de hablar de la identificación de dispositivos de forma remota. Existen varias alternativas para realizar este proceso. Por una parte, se puede identificar la clase del dispositivo, es decir, si es un ordenador, una impresora, un dispositivo Internet of Things (IoT), etc. Por otra parte, se puede identificar el modelo del dispositivo,

por ejemplo, distinguir un dispositivo de una marca A y modelo B de uno que sea de marca X y modelo Y. Por último, y la parte más difícil, se pueden distinguir dispositivos a nivel individual, aunque presenten el mismo hardware.

Por todas las razones expresadas anteriormente, existe la pregunta sobre cómo se puede saber con qué equipos se está estableciendo una comunicación, o qué diferencia a un dispositivo de otro en internet si ambos presentan los mismos identificadores. En la actualidad existen formas de asegurar la identidad de un usuario o dispositivo, como los certificados digitales expedidos por autoridades de certificación, en España, la Fábrica Nacional de Moneda y Timbre (FNMT). Sin embargo, estas opciones pueden ser clonadas junto con el resto del software de un dispositivo [52].

Una respuesta a estas preguntas es que los dispositivos aunque presenten el mismo hardware, tengan los mismos identificadores hardware (como dirección IP o MAC) o software (como certificados digitales o claves) , y ejecuten el mismo software, nunca serán exactamente iguales. Esto es debido a que en el proceso de fabricación de los dispositivos siempre habrá diferencias (por pequeñas que sean) que harán que los dispositivos sean distinguibles entre sí, por ejemplo, un dispositivo ejecuta una función en 1.2 ns y otro en 1.4 ns. Las diferencias son mínimas, pero existen [3].

Por contra, varias de las soluciones encontradas y comentadas en el capítulo de *Estado del arte* (Capítulo 2) trabajan de forma distinta. Algunas de ellas se basan en identificar un modelo de dispositivo, pero no un dispositivo individual.

En el panorama actual del Big Data y el Machine Learning, podemos explotar las diferencias comentadas anteriormente de tal forma que se generen huellas de cada dispositivo y con ello saber si realmente nos estamos conectando con el dispositivo adecuado o no.

En este marco de trabajo es en el que se centra este proyecto. Se busca crear un sistema que partiendo de un punto de sincronización en común, compare las desviaciones de los relojes de los distintos dispositivos y con ello cree una huella estadística del comportamiento de cada uno. Posteriormente se automatizará el proceso de analizar esos valores estadísticos mediante un modelo de Machine Learning.

Para lograr el objetivo principal del trabajo, en la identificación de dispositivos idénticos de forma automática, se han establecido diversas metas intermedias:

- **Objetivo 1.** Presentar la arquitectura IoT, así como sus diversas aplicaciones.
- **Objetivo 2.** Presentar distintas soluciones dentro del campo del Machine Learning que pueden ser aplicadas a nuestro problema.
- **Objetivo 3.** Diseñar una arquitectura de trabajo propia, que será seguida en todo el desarrollo del proyecto.
- **Objetivo 4.** Analizar las distintas formas de obtener una marca de tiempo, con suficiente precisión, de un dispositivo.
- **Objetivo 5.** Generar un dataset con las distintas desviaciones de reloj de los dispositivos bajo análisis.

-
- **Objetivo 6.** Analizar estadísticamente las diferencias entre los distintos relojes de los dispositivos, con el fin de ver si son estadísticamente diferenciables.
 - **Objetivo 7.** Generar un nuevo dataset con distintas variables estadísticas de las desviaciones previas. Donde se eliminarán las variables correlacionadas.
 - **Objetivo 8.** Evaluar distintos algoritmos de Machine Learning para la tarea de distinguir entre los dispositivos.
 - **Objetivo 9.** Comparar los resultados obtenidos con las soluciones ya existentes y describir las vías futuras de esta línea de investigación.

El resto del presente documento se estructura como se indica a continuación. En el capítulo de *Estado del arte* (Capítulo 2) se realiza una presentación de la arquitectura IoT y sus aplicaciones, así como, una presentación del Machine Learning y algunos de sus algoritmos. En el capítulo de *Análisis de objetivos y metodología* (Capítulo 3) se analizan los objetivos propuestos y se establece una metodología de trabajo. En el capítulo de *Diseño y resolución* (Capítulo 4) se hablará de nuestra propuesta para abordar este problema. Se obtendrán varios dataset y con ellos se entrenarán diversos modelos de Machine Learning. En el capítulo de *Resultados* (Capítulo 5) se analizarán los resultados obtenidos, en concreto, se evaluarán los distintos clasificadores usados. Finalmente en el capítulo de *Conclusiones y vías futuras* se exponen las conclusiones finales del trabajo y se comentan posibles vías futuras para esta línea de investigación.

CAPÍTULO 2

Estado del arte

En este capítulo se introducirán los conceptos de dispositivos y arquitectura IoT, así como de Machine Learning. También se explicarán los algoritmos de aprendizaje utilizados en el desarrollo de este trabajo.

2.1 Dispositivos IoT

En esta sección se introducirá la arquitectura IoT, así como sus aplicaciones en el mundo actual.

2.1.1 Introducción

El Internet de las Cosas, más conocido por Internet of Things (IoT), es el conjunto de dispositivos capaces de conectarse a internet, recolectar e intercambiar datos de forma autónoma. Una cosa que distingue a los dispositivos IoT de los que no lo son, es que estos dispositivos pueden interactuar entre ellos sin necesidad de intervención humana.

El concepto de IoT fue primeramente mencionado por Kevin Ashton en 1999 mientras realizaba una presentación sobre dispositivos Radio Frequency Identification (RFID) [14]. A pesar de esto el primer dispositivo de este tipo fue una máquina de refrescos en 1982 [48], que se conectaba a internet para informar los refrescos que contenía, y si estos se encontraban fríos.

2.1.2 Arquitectura IoT

Cada vez hay más dispositivos IoT conectados a internet, lo que dada su naturaleza, implica que son varias miles de millones de ellos. Por este motivo, los protocolos de la pila TCP/IP no están preparados para este número tan grande de dispositivos que manejar.

Existen diversas propuestas sobre arquitecturas multi capa que puedan asegurar los requisitos de calidad de servicio (QoS) y seguridad requeridos. En la propuesta de Muhammad Umar Farooq et al. [12] se hace mención a una arquitectura de 6 capas.

Por otro lado, en la propuesta de Ibrar Yaqoob et al. [51] se explica una propuesta más general, combinando varias de las capas que comparten gran parte de su cometido. Esta propuesta se puede observar gráficamente en la Fig. 2.1. A continuación se explican esas 3 capas:

1. **Capa sensitiva:** esta es la capa más básica. Es la que se encarga de recolectar toda la información que sea capaz el dispositivo a través de sus múltiples sensores.
2. **Capa de transporte:** esta capa es la que realiza todo el intercambio de información entre las otras dos capas. Se encarga de las operaciones de red.
3. **Capa de aplicación:** esta capa se encarga de extraer la información valiosa de los datos producidos por la capa sensitiva, y que le llegan a través de la capa de transporte. En esta capa se agrupan distintos servicios como data mining o computación en la nube.




Figura 2.1: Arquitectura IoT propuesta [51]

2.1.3 Aplicaciones del IoT

En la actualidad, se vive rodeados de dispositivos inteligentes. Estos dispositivos permiten realizar todo tipo de acciones, por ejemplo, un teléfono móvil permite enviar y recibir emails, enviar mensajes instantáneos, utilizar redes sociales, etc. A pesar de todas esas funciones, todos estos aparatos comparten un “problema”, necesitan de la intervención humana para realizar sus tareas.

De estas necesidades nacen los dispositivos IoT, por ejemplo, un frigorífico inteligente. Este frigorífico es capaz de llevar el inventario de productos que contiene y detectar cuando alguno de ellos está próximo a terminarse. De forma autónoma este dispositivo es capaz de

conectarse a internet y realizar una pedido online al supermercado de nuestra preferencia para reabastecerse de estos productos.

Este es sólo un ejemplo, dentro del hogar se pueden encontrar también los muy conocidos robots aspiradora o los asistentes inteligentes, pero estos dispositivos pueden ir mucho más lejos. Estos dispositivos se pueden usar para un control inteligente del tráfico, donde un coche autónomo puede recibir en tiempo real las rutas menos congestionadas que seguir hacia un destino.

Otro de sus posibles usos está en la medicina. Donde se pueden instalar dispositivos de este tipo para medir distintas métricas de salud de los pacientes, como la frecuencia cardíaca o el nivel de glucosa en sangre. De esta forma, en caso de que una persona presente algún desorden, una ambulancia puede ser avisada de forma inmediata aunque dicha persona esté sola e inconsciente.

Como último ejemplo se mencionará al sector agrícola. En este campo se pueden desplegar drones que detecten el nivel de humedad del terreno y, por ejemplo, activen el riego de cierta zona en caso de ser necesario. También pueden haber sensores a nivel del suelo que detecten la calidad del suelo, midiendo los distintos nutrientes y actuando en consecuencia.

2.2 Machine Learning

En esta sección se introducirá el concepto de Machine Learning, los diferentes tipos de aprendizaje, así como

2.2.1 Introducción

El Machine Learning se trata de una búsqueda, una búsqueda de formas alternativas de hacer algo. Para ello se busca en estructuras muy similares a las previas. Para modificar una estructura y seguir con la búsqueda nos valemos de sucesos que hayan acontecido, entonces, evaluamos si han mejorado y nos quedaremos como estructura para la siguiente iteración con la que más mejore a la previa. Para realizar estas operaciones necesitamos una forma de cambiar de estructura y una forma de evaluar si hemos mejorado.

Con esta forma de trabajar se puede ver que el programa no tiene que resolver la tarea sino autoajustarse para obtener mejores evaluaciones cada vez. El programador por tanto no pone el programa sino proporcionar al programa la mejor estructura modificable y a continuación alimentar al sistema con datos. Aportamos por tanto ejemplos o premios que ayudan al programa a autoajustarse. Existen tres tipos de aprendizaje:

- **Supervisado:** al sistema se le proporcionan ejemplos de cuales la solución es conocida. Una variante sería el semi-supervisado en el que sólo una parte de los datos tienen solución conocida.
- **No Supervisado:** al sistema se le proporcionan datos que no tienen una solución conocida, esperando que el sistema nos proporcione conocimiento que intuimos que existe en dichos datos. Un ejemplo sería el *clustering* que agrupa los datos por similitudes.

- **Por refuerzo:** al sistema no se le pasan ejemplos de datos, sino que se le premia o castiga por distintas conductas que desarrolla automáticamente. Al final el sistema, que busca obtener más premios, se comportará de la forma que queremos.

2.2.2 Tratamiento de los datos

Para obtener un resultado de cuan bueno es un modelo (algoritmo) que se quiere usar se debe dividir el conjunto de datos inicial en dos conjuntos: **datos de entrenamiento** y **datos de test**. Con los datos de entrenamiento el algoritmo se ajusta y aprende de los ellos, y con los datos de test se analizan los resultados obtenidos del algoritmo ante datos que no ha visto antes.

Para realizar una comparación entre distintos modelos donde se quiere ver cual es el que mejor se ajusta a los datos se debe dividir el conjunto de datos de entrenamiento en otros dos conjuntos: **conjunto de entrenamiento** y **conjunto de validación**. Con este último se puede evaluar la capacidad de generalizar de nuestro algoritmo.

Con esta segunda división se obtiene el algoritmo que mejor se adapta a los datos, pero no un modelo final. Para tener un modelo final se entrenará este con el conjunto de datos de entrenamiento en su totalidad y se evaluará con los datos de test.

2.2.3 Algoritmos de Machine Learning

2.2.3.1 Algoritmos de aprendizaje supervisado

Dentro de los algoritmos de aprendizaje supervisado se encuentran algoritmos que clasifican y algoritmos que se dedican a la regresión.

Los algoritmos clasificadores tratan de agrupar a los distintos vectores de entrada en distintas clases. Un ejemplo de esto sería un algoritmo de clasificación binaria, en la que existen ejemplos **positivos** (pertenecen a la clase) o **negativos** (no pertenecen). Esto genera los conceptos de **falso positivo** (el sistema dice que pertenece y es falso) y **falso negativo** (el sistema dice que no pertenece y es falso).

Los algoritmos regresores buscan dar una salida numérica como resultado en lugar de la pertenencia a una clase, por tanto no sirven para este trabajo. A continuación se explicarán los algoritmos que se han usado para el desarrollo de este trabajo.

Árboles de decisión

La idea principal del algoritmo es que partiendo de un conjunto de elementos en el nodo padre, haciendo una pregunta binaria tal que se puede dividir el conjunto en otros 2 que sean más puros, es decir, que los elementos entre sí compartan (al menos) la característica por la que hemos preguntado.

Si los atributos son categóricos se puede crear una partición diciendo si pertenecen o no a la clase. Por contra, si los atributos son ordinales se pueden tener preguntas del tipo $x \leq x_c$.

Random Forest

Este algoritmo es un conjunto de árboles de decisión trabajando en paralelo. Cada árbol realizará de forma aleatoria una partición distinta a los otros para cada división de una rama, con esto se obtiene variabilidad en los resultados de los árboles. Por último, el algoritmo toma como salida aquella clase que haya sido el resultado de más árboles [6][17].

Multilayer Perceptron (MLP)

Se trata de un modelo de red neuronal artificial de tipo *feed-forward* (es decir, no existen ciclos en el grafo que forma la red). Consiste en una serie de múltiples capas (multilayer) de nodos que conforman grafos dirigidos, estando cada capa conectada con la siguiente [29].

MLP entrena la red utilizando la propagación hacia atrás (backpropagation) que, empleada junto con una técnica de optimización como gradient descent, calcula el gradiente de una función de pérdida respecto a todos los pesos en la red, de manera que se pasa el valor del gradiente al método de optimización y este lo usa para actualizar los pesos, con el objetivo de minimizar la función de pérdida.

Naive Bayes

Los algoritmos de aprendizaje bayesianos tratan de encontrar la probabilidad de que un dato pertenezca a una clase. Una vez se tienen todas las probabilidades de pertenencia a una clase se toma como salida del algoritmo aquella clase con la mayor probabilidad [28].

Para realizar este proceso el algoritmo usa distintos atributos de cada dato a_1, \dots, a_n . Ahora este proceso se trata de conocer la probabilidad condicionada de que este conjunto de atributos pertenezca a una determinada clase. Esto es muy costoso y por tanto hay que relajar esta hipótesis. Para ello se asume independencia entre los atributos de ahí el nombre de *naive*.

K Nearest Neighbours (KNN)

El algoritmo KNN es un algoritmo que se usa mayoritariamente para clasificación. En este algoritmo los datos se agrupan por distancias [35].

A la hora de clasificar un nuevo dato, este algoritmo busca los k datos más cercanos. Una vez tiene esos datos comprueba sus clases. La clase con mayor representación entre los k datos es la que se asignará al nuevo dato. Podemos verlo con un ejemplo.




Figura 2.2: Funcionamiento del algoritmo KNN [9]

En la Fig. 2.2 se quiere clasificar el dato ●, una opción es usar múltiples valores de k y con ello obtener diferentes resultados:

- Asignando $k = 3$ sólo se tendrán en cuenta los 3 datos más próximos, que serán 2 de la clase ▲ y uno de la clase ■. Con esto la clase que se asignará al dato ● será ▲.
- Asignando $k = 5$ sólo se tendrán en cuenta los 5 datos más próximos, que serán 2 de la clase ▲ y tres de la clase ■. Con esto la clase que se asignará al dato ● será ■.

Máquinas de vector soporte (SVM)

Las máquinas de vector soporte son un conjunto de algoritmos de aprendizaje supervisado que se utilizan tanto para clasificación como para regresión, en este caso se analizará únicamente en clasificación.

Estos algoritmos toman los datos como puntos en un espacio n -dimensional. El objetivo es dividir estos datos mediante hiperplanos de forma que los puntos que contenidos en una región del espacio delimitada por los mismos hiperplanos sean una misma clase y que estén lo más separados posible [7]. Este proceso se puede ver de una forma más sencilla a través de un ejemplo.

En la Fig. 2.3 se puede ver como hay distintos hiperplanos $(\mathcal{H}_1, \mathcal{H}_2, \mathcal{H}_3)$ que pueden dividir el espacio.

- \mathcal{H}_1 no divide de forma correcta todos los puntos de la entrada, puesto que hay puntos negros juntos con blancos.
- \mathcal{H}_2 sí que divide a todos los puntos en dos clases de la forma correcta, pero no están seraparas lo máximo posible de este hiperplano.
- \mathcal{H}_3 sí que cumple con las restricciones de división y distancia máxima.




Figura 2.3: Separación por hiperplanos SVM [10]

En muchas ocasiones no se podrán dividir los conjuntos de forma correcta usando únicamente divisiones lineales del espacio, por ello, habrá que usar divisiones no lineales.

2.2.3.2 Algoritmos de detección de anomalías

Isolation Forest

En este trabajo se ha presentado el algoritmo Random Forest, el cual es un algoritmo de aprendizaje supervisado orientado a clasificación. El algoritmo Isolation Forest [23] [8] se basa Random Forest con el objetivo de obtener un algoritmo orientado a la detección de anomalías.

Para lograr esto, este algoritmo aprovecha dos características de un valor anómalo. Por un lado, se espera que los valores anómalos sean minoritarios en la muestra, y por el otro, se espera que dichos valores presenten características muy distintas a los datos legítimos.

Partiendo de estas premisas se pueden identificar los valores anómalos en un árbol de decisión como aquel que ha necesitado menos preguntas binarias para quedar separado. Esto se extiende a varios árboles para que esta detección sea tomada entre la mayoría. Un ejemplo de uso de este algoritmo se puede ver en la Fig. 2.4.

Local Outlier Factor (LOF)

El algoritmo de detección de anomalías Local Outlier Factor (LOF) [8] utiliza la densidad de puntos como predictor de valores anómalos. Para cada dato se calcula su densidad local, es decir, cuántos datos vecinos se sitúan cerca de este.

Una vez se tienen todos los valores de densidad de cada dato, se ordenan de forma descendente y se seleccionan los m (variable de entrada del algoritmo) primeros como valores anómalos.




Figura 2.4: Ejemplo de OneClass-SVM [19]

OneClass SVM (OC-SVM)

Anteriormente se ha explicado el algoritmo SVM, el cual pertenece a los algoritmos de aprendizaje supervisado orientados a la clasificación. En este apartado se presenta un algoritmo basado en SVM orientado a la detección de anomalías. Este algoritmo recibe el nombre de OneClass-SVM (OC-SVM) [22].

La idea de este algoritmo es ser entrenado únicamente con datos pertenecientes a una misma clase. De esta forma, y al igual que pasaba con SVM, se generan hiperplanos que dividen el espacio n -dimensional de manera que los datos de esta clase estén contenidos en la misma región.

Una vez se tiene un modelo entrenado, en la etapa de test, se situará el nuevo dato como un vector en dicho espacio, produciéndose dos situaciones: está contenido en la región del espacio que ocupan los datos de la clase o, por contra, no está contenido en esa región. En caso de estar contenido se le asigna el valor 1 y en otro caso se le asigna el valor -1 , quedando de esta forma identificado como anomalía o no. Un ejemplo de uso de este algoritmo se puede ver en la Fig. 2.5.

2.3 Revisión bibliográfica

En esta sección se realiza un estudio del estado del arte relativo a la aplicación de distintas técnicas que tengan como objetivo identificar a un dispositivo a través de la red independientemente de un identificador susceptible de ser identificado. Para estos cometidos son muy utilizados los algoritmos de aprendizaje automático o Machine Learning.

Para comenzar la revisión bibliográfica, se analizará el trabajo desarrollado por Pascal




Figura 2.5: Ejemplo de Isolation Forest [32]

Oser et al. [33]. En este trabajo se desarrolla un sistema para identificar dispositivos entre un total de 562 en el centro del Conseil Européen pour la Recherche Nucléaire (CERN). Para este cometido se toman muestras periódicas de las marcas de tiempo (timestamps) contenidas en paquetes TCP que se envían y reciben de estos dispositivos.

De estas marcas se obtienen las variables que se usarán para entrenar los distintos modelos de machine learning. Las variables que obtiene son el incremento entre dos marcas consecutivas, el desbordamiento del contador de la marca de tiempo, la mediana de todas las marcas, etc.

Una variable interesante es la del desbordamiento del contador. En el RFC 1323 [5] se define que el contador del timestamp (campo TSval) tiene una longitud de 4 bytes (32 bits), por lo tanto, el mayor valor que podrá tener asignado es 2^{32} , puesto que es un entero sin signo. Se podría pensar que todos los dispositivos desbordan a la vez, pero cada fabricante establece el valor al que el contador se desborda. Esto está ilustrado en la Fig. 2.6 con dos ejemplos.

Una vez tiene todas las variables registradas para todos los dispositivos, compara varios modelos de machine learning, para clasificar cada uno de los dispositivos. Los resultados que obtiene son de un accuracy del 99.22 % con MLP, un 99.14 % con SVM y por último 99.67 % con Random Forest.

Con estos datos decide quedarse con el modelo de Random Forest, el cual entrena con la totalidad de los datos de entrenamiento, obteniendo finalmente una precisión del 97.03 % y un accuracy del 99.76 %.

Otro trabajo relacionado con la temática ha sido desarrollado por Salma Abdalla Hamad et al. [16]. En este trabajo se desarrolla un sistema que identifique a un dispositivo que quiere conectarse a la red y decida si se le permite realizar esta acción o se le deniega. Además este




Figura 2.6: Desbordamiento del contador [33]

sistema comprobará periódicamente los dispositivos que están ya en la red para detectar comportamientos malintencionados.

Este sistema (Fig. 2.7), una vez se tiene una traza del dispositivo que se quiere conectar por primera vez a la red, crea una huella del dispositivo que será analizada por un modelo (previamente entrenado) que lo clasificará como desconocido o no, en caso de que esté en una lista blanca. En caso de ser un dispositivo desconocido se le denegará el acceso a la red. Por contra, si está en la lista, se consultará una matriz de autorización (que contiene la confianza de ese dispositivo según sus vulnerabilidades) para saber que privilegios recibirá ese dispositivo. Con esto el dispositivo puede conectarse como un dispositivo “confiable”, teniendo acceso a comunicarse con todos los dispositivos de la red, o por contra, de “acceso restringido” donde solo podrá comunicarse con dispositivos de ese mismo nivel de acceso.

Para los dispositivos que ya están conectados a la red, se toma una muestra aleatoria que comprobará si se han clasificado de forma correcta. En el caso de que se haya clasificado mal pero siga estando en la lista blanca se actualizará su matriz de autorización. Por otra parte, en caso de que no esté en dicha lista se pondrá en cuarentena para ser analizado más adelante.

Las huellas de los dispositivos se obtienen del payload de los mensajes enviados por ese dispositivo. De ellos se obtienen 67 características como el tamaño del paquete Ethernet, el tamaño de las cabeceras, la IP de destino, el Time To Live (TTL), etc.

Con estas huellas entrena distintos modelos como son AdaBoost, Árboles de decisión, Linear Discriminant Analysis (LDA), KNN, Naive Bayes, SVM, Random Forest y GBoost. Obtuvo un accuracy final del 89 %.

El siguiente artículo que se analizará es el realizado por Ahmet Aksoy et al. [2]. Este trabajo diseña un sistema (llamado SysID) que es capaz de identificar dispositivos a través del tráfico de red.

Este sistema únicamente necesita un paquete de red para identificar el dispositivo. Dado un paquete de la traza se seleccionan n cabeceras del paquete mediante un algoritmo genético, que implementa una función fitness (Eq. 2.1) que trata de reducir este número de cabeceras.

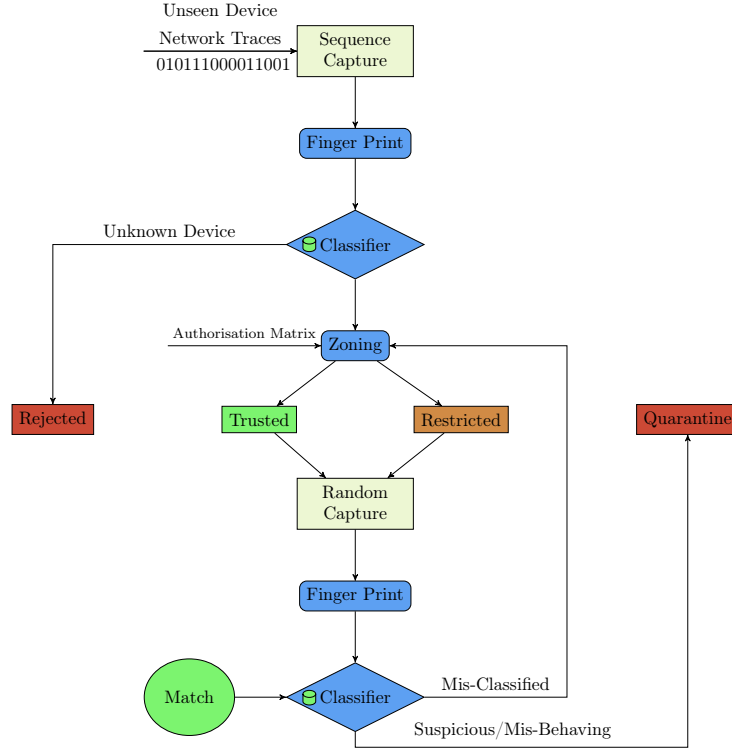


Figura 2.7: Modelo del sistema de identificación [16]

$$Fitness = 0.9 \cdot Accuracy + 0.1 \cdot \left(1 - \frac{|SelectedFeatures| - 1}{|AllFeatures| - 1}\right) \quad (2.1)$$

donde $n = |SelectedFeatures|$ y $Accuracy$ es el resultado que se obtiene del modelo de machine learning entrenado con esas cabeceras.

Las trazas que se han usado para clasificar estos dispositivos provienen de una base de datos de otro artículo [26], de donde se obtienen 20 medidas de 23 dispositivos IoT.

Para la clasificación se han usado diferentes algoritmos de la herramienta Waikato Environment for Knowledge Analysis (WEKA) [15] como son tablas de decisión, árboles de decisión J48, OneR y PART. Se decide usar una clasificación en dos niveles (Fig. 2.8), se clasifican primero entre su proveedor o el propio dispositivo, dependiendo de si hay más de un mismo dispositivo del mismo proveedor. Después se clasifican los dispositivos del mismo proveedor entre sí. Este esquema ayuda a tener mejores resultados pues cada proveedor puede ser identificado de mejor forma por un algoritmo distinto.

Los resultados que obtiene son de un 82 % de accuracy promedio entre todos los clasificadores de cada proveedor. Los valores individuales están entre el 42.2 % y el 100 %.

El siguiente trabajo que se verá es el realizado por Hossein Jafari et al. [20]. En este artículo no se utilizan paquetes de la capa de red o transporte, sino de la capa física. Para realizar esta labor se obtendrá la huella de cada dispositivo mediante radio frecuencias, por esta razón, este estudio sólo se centrará en conexiones inalámbricas, en este caso 6 dispositivos ZigBee [13].

Para cada uno de los dispositivos se realiza una captura de 5 minutos. Esta captura será

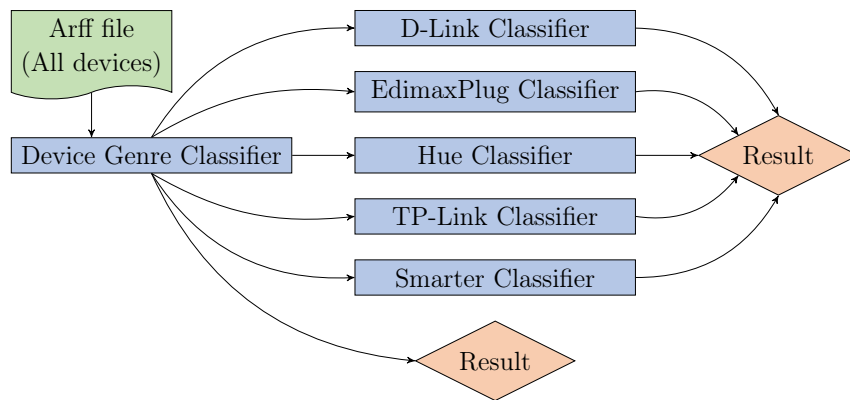


Figura 2.8: Clasificador de dos niveles [2]

del SNR en 5 niveles distintos, con lo que se obtiene 10 GB por dispositivo y nivel de SNR, lo que en total serían 300 GB de datos.

A continuación procede a entrenar tres algoritmos de Deep Learning, DNN, CNN y LSTM (los tres modelos pertenecen a la librería **TensorFlow** programada para Python [1]), con los que obtiene unos resultados de 96.3 %, 94.7 % y 76 % respectivamente.

Fabian Lanze et al. [21] han desarrollado un trabajo en el que crean un sistema de identificación de dispositivos basado en el clock skew. Su objetivo es generar huellas para cada punto de acceso, de forma que si un dispositivo pueda saber si ese punto de acceso es legítimo, o por contra si puede ser un potencial atacante.

Lo primero que hacen es definir el skew de un reloj como la primera derivada del offset de dicho reloj. De forma práctica usarán la desviación que almacena el demonio del servicio NTP para aproximar el skew del dispositivo conectado al punto de acceso. Usará conexión inalámbrica y recogerá hasta 6000 paquetes por dispositivo en cada muestra (10 minutos). Si en una muestra no se alcanzan los 500 paquetes, por problemas de conexión o cualquier otro motivo, esa muestra se elimina. Con este proceso se consiguen medir 388 puntos de acceso.

Finalmente, trata de generar una huella para cada punto de acceso de forma estadística, basándose sobre todo en la distribución del clock skew. Como resultado obtiene que su método no es suficientemente preciso y que muchos dispositivos presentan una huella similar, por lo tanto, concluye que no es posible identificarlos únicamente de esta forma.

En el trabajo desarrollado por Yair Meidan et al. [24] se desarrolla un sistema que es capaz de identificar dispositivos IoT a través de su tráfico de red. Las pruebas se realizan con trazas sobre conexión inalámbrica y tanto con dispositivos IoT como con PCs, smartphones, etc.

De estas trazas se centran específicamente en las sesiones TCP, donde cada una se representa como un conjunto de características de cada paquete.

Primeramente, ejecutan un clasificador binario con el que obtienen la probabilidad de que un dispositivo sea IoT, usando solo información de una sesión TCP de cada dispositivo. En este apartado obtienen un 100 % de acierto.

Por último, entrenan distintos modelos de clasificación, tales como Gradient Boost Ma-

chine (GBM), Random Forest, XGBoost, únicamente sobre los dispositivos previamente etiquetados como IoT, obteniendo finalmente un resultado de un 99.281 % de accuracy en la identificación del modelo y marca de cada uno de ellos.

Como último artículo se analizará la propuesta realizada por Loh Chin Choong Desmond et al. [11]. En este trabajo han construido un sistema de identificación de dispositivos basado en los mensajes *probe request* de los distintos dispositivos. Para ello, distinguirán como dispositivos distintos las distintas combinaciones de la tupla: ⟨“Machine”, “Wireless Network Interface Card (NIC) Driver”, “Operating System”⟩.

A continuación, comprueban que en el tiempo de emisión de estos mensajes se ven varios comportamientos que se repiten. Luego, observan que la latencia entre ráfagas de estos mensajes también presenta estos comportamientos distintivos. Con estas latencias son con las que entrenarán un modelo que sea capaz de distinguir los dispositivos.

El modelo que eligen se basa en aprendizaje no supervisado, Maximum Variance Clustering [49]. Este modelo es similar al algoritmo de k -medias, la distinción es que k -medias necesita conocer previamente el número de clústeres k previamente, mientras que Maximum Variance Clustering necesita conocer la varianza máxima dentro de un clúster σ_{max}^2 . Con este algoritmo obtienen unos resultados de accuracy entre el 70 % y el 80 %.

2.3.1 Resultados de la revisión bibliográfica

Por último se ha realizado un resumen en forma de tabla de los artículos que han sido revisados. Se puede consultar la Tabla 2.1

En esta revisión bibliográfica se ha llegado a la conclusión de que a pesar de que existen diversas soluciones de identificación de dispositivos, solo una de ellas utiliza mecanismos hardware, la propuesta de Hossein Jafari et al. [20]. El resto de propuestas se centran en aspectos software, en particular en diversas características de los envíos TCP. Otra de las carencias encontradas ha sido la del nivel de identificación deseado, en varias propuestas no se busca una identificación individual de los dispositivos, únicamente se atiende a clasificarlos por fabricante, modelo y demás características que no identifican a un dispositivo de forma unívoca.

Debido a estas razones, la solución propuesta en este trabajo propone un método de identificación a más bajo nivel que puede ser usada para incrementar la seguridad de diversos entornos que deben permanecer seguros ante posibles ataques.

Referencia	Tipo de identificación	Fuente de los datos	Enfoque	Tipo de aprendizaje	Algoritmos usados	Resultados
[33]	Tipo de dispositivo	Cabeceras TCP	Machine Learning	Supervisado	MLP, SVM, Random Forest	99.76 % de accuracy y 97.03 % de precisión
[16]	Individual	Características del payload	Machine Learning	Supervisado	AdaBoost, LDA, KNN, Árboles de decisión, Naive Bayes, SVM, Random Forest y GBoost	89 % de accuracy
[2]	Tipo y modelo del dispositivo	Cabeceras TCP	Machine Learning	Supervisado	Tablas de decisión, Árboles de decisión J48, OneR y PART	Entre 42.2 % y 100 % de accuracy, con un promedio de 82 %
[20]	Individual	Radio frecuencias	Machine Learning	Supervisado	DNN, CNN y LSTM	96.3 % de accuracy en DNN, 94.7 % de accuracy en CNN y 76 % de accuracy en LSTM
[21]	Modelo del dispositivo	Registros NTP	Análisis estadístico (regresión lineal)	-	-	Método no válido para identificar unívocamente un dispositivo.
[24]	Tipo y modelo	Sesiones TCP	Machine Learning	Supervisado	GBM, Random Forest y XGBoost	99.281 % de accuracy
[11]	Individual	Mensajes <i>probe request</i>	Machine Learning	No supervisado	Maximum Variance Clustering	Entre un 70 % y 80 % de accuracy
Este trabajo	Individual	Ciclos de CPU	Machine Learning	Supervisado y No supervisado	Random Forest, MLP, Naive Bayes, KNN, Árboles de decisión, SVM-Linear, LOF, OC-SVM, Isolation Forest	99.38 % de Accuracy, 99.39 % de Recall y 99.38 % de <i>f</i> -score

Tabla 2.1: Resultados en el estado del arte

CAPÍTULO 3

Análisis de objetivos y metodología

En esta sección se analizarán los objetivos del trabajo y se realizará un análisis sobre las decisiones tomadas en el proceso de identificar dispositivos.

3.1 Análisis de objetivos

El principal objetivo de este proyecto es conseguir identificar dispositivos idénticos. La solución que se propone es capaz de identificar los patrones relativos a la desviación de sus relojes internos y usarlos para reconocer a cada dispositivo mediante un modelo de Machine Learning. Para lograr dicho objetivo han sido establecidas diversas metas intermedias:

- Usar lo visto en el estado del arte, para conocer y seleccionar los desafíos de este proyecto.
- Conseguir un registro de los relojes internos de cada uno de los dispositivos que se van a participar en el análisis. Para lo que definiremos una estructura cliente-servidor que recogerá un registro de los datos.
- Generar una huella estadística de estos registros mediante el uso de una ventana deslizante que permite agrupar los datos y extraer estadísticas comunes. Eliminando variables correlacionadas.
- Analizar distintas propuestas de algoritmos de Machine Learning que sean capaces de tomar como entrada las huellas estadísticas y, con ellas, identificar a cada dispositivo.

3.2 Metodología de trabajo

Para poder alcanzar los objetivos propuestos, se presenta una metodología de trabajo.

1. **Revisión bibliográfica.** Revisión de los trabajos relacionados con el tema de este trabajo. En concreto, se busca comprender cómo obtienen sus datos y su método de clasificación de dispositivos.
2. **Diseño de la arquitectura de trabajo.** Se diseña un procedimiento a seguir de forma genérica. Basándose en ese procedimiento se lleva a cabo el resto del trabajo.
3. **Recolección de los datos.** Generación de un dataset que contiene las marcas de tiempo tanto del dispositivo de referencia como del que se encuentra bajo análisis. Este proceso se realiza por cada dispositivo a analizar.
4. **Generación de huella estadística.** Por cada dispositivo se hace uso de una ventana deslizante que agrupa los datos en grupos de n muestras. De cada grupo se obtienen un conjunto de variables estadísticas que son etiquetadas con el dispositivo del que se han obtenido.
5. **Búsqueda de variables correlacionadas.** Se realiza un test de correlación a los datos con el fin de reducir la dimensionalidad de los mismos. Las variables correlacionadas no aportan información y por ello han de ser eliminadas.
6. **Particionamiento del conjunto de datos.** Con el fin de entrenar algoritmos de Machine Learning, se divide el conjunto de datos en dos de menor tamaño (entrenamiento y test).
7. **Ajuste de hiperparámetros.** Para decidir cuál de los algoritmos es mejor para clasificar los datos de este trabajo se comparan distintos algoritmos de Machine Learning. Estos algoritmos han de ser ajustados correctamente para obtener los mejores resultados. Para realizar este ajuste se realiza una partición similar a la realizada con el conjunto de todos los datos, pero con un conjunto reducido de forma que los entrenamientos duren menos tiempo.
8. **Evaluación de los distintos modelos.** Una vez entrenados todos los algoritmos que se quieren comparar, se comparan sus resultados identificando dispositivos para elegir al mejor candidato.
9. **Entrenamiento del modelo final.** Decidido el algoritmo que se va a usar y sus hiperparámetros, se realiza un entrenamiento final con el conjunto completo de los datos de entrenamiento.
10. **Evaluación del modelo final.** Análisis de los resultados finales obtenidos.

CAPÍTULO 4

Diseño y resolución

En este capítulo se realiza la descripción de los experimentos realizados, su análisis y la búsqueda de un modelo de Machine Learning, así como los resultados finales del trabajo.

En este trabajo se usará una topología de red como la que ilustra la Fig. 4.1. En dicha topología se puede ver que tenemos un observador (modelo RockPro64) y 5 dispositivos a analizar (Raspberry Pi 4 Model B).

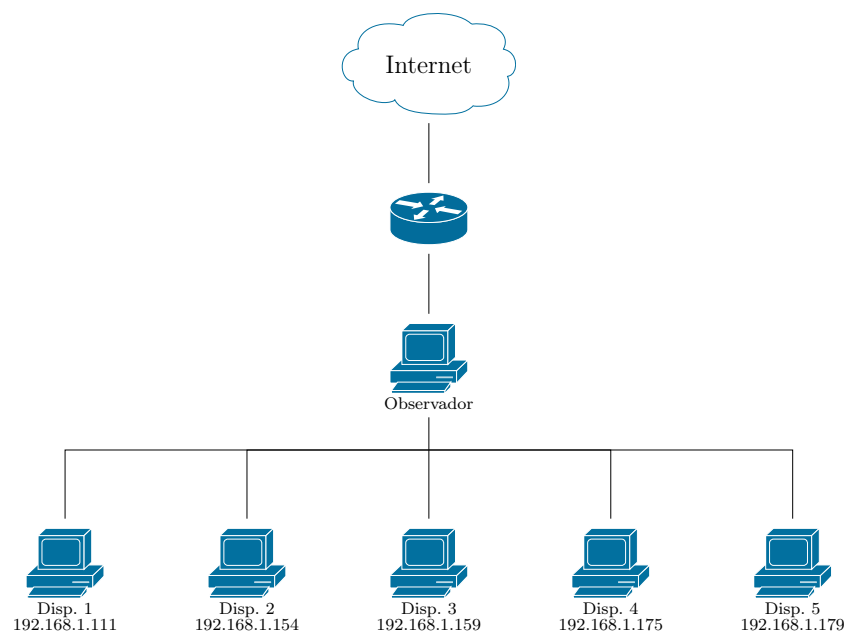


Figura 4.1: Topología de la red

La idea es enviar mensajes desde el observador a cada uno de los dispositivos y que cada uno de los dispositivos responda a esos mensajes, obteniendo así una marca de tiempo de ese dispositivo.

4.1 Arquitectura propuesta

En este trabajo ha sido propuesta una arquitectura en la que se basará todo el desarrollo del mismo. Esta arquitectura se puede ver en la Fig. 4.2.




Figura 4.2: Arquitectura propuesta

Esta arquitectura se compone de dos partes. Por una parte, los dispositivos que generan y comparten los datos, y por otra parte el dispositivo externo que se encarga de tanto de analizar y procesar los datos, como de ajustar los algoritmos de Machine Learning que se usan. Este dispositivo también es el encargado de evaluar los resultados que obtienen los modelos ya entrenados y compararlos entre ellos. A continuación se explicarán cada una de estas partes.

- A) Establecimiento de las condiciones.** En esta fase se preparan los dispositivos para la recolección de las muestras. Se establecen frecuencias de CPU fijas, para evitar que esto afecte a los ciclos del procesador. También se deshabilita el servicio NTP que modifica el reloj interno del dispositivo.
- B) Recolección de datos.** En esta fase se obtienen los datos de los distintos dispositivos que van a ser analizados. Cada segundo estos dispositivos obtienen el valor de su reloj interno y lo envían al cliente. Este proceso se repite durante la obtención de toda la muestra, que debe de ser un periodo de tiempo suficientemente largo.
- C) Análisis y procesamiento de los datos.** En esta fase el cliente obtiene cada una de las marcas de tiempo de los dispositivos. Con estos valores calcula el incremento entre cada par de marcas de un dispositivo y con ello construye un conjunto de datos. Sobre este conjunto de datos, y mediante el uso de una ventana deslizante, se obtienen diversos valores estadísticos que serán representativos de la ventana en cuestión. Algunos de

estos valores pueden presentar correlación entre sí, por ello, se obviarán todos excepto uno que servirá de representante.

- D) **Generación de los modelos.** En esta fase se seleccionan los distintos algoritmos de Machine Learning que se usarán en este trabajo. En este proyecto se ha optado por usar algoritmos de aprendizaje supervisado orientados a clasificación, y algoritmos de aprendizaje no supervisado orientados a la detección de anomalías. Una vez se sabe cuales serán los algoritmos a usar, se procede a ajustar sus hiperparámetros con el objetivo de hacer que los modelos resultantes se ajusten de la mejor manera posible a los datos de este trabajo.
- E) **Evaluación de los modelos.** En esta fase se eligen las métricas que se van a usar para comparar los distintos modelos entre sí. Se seleccionan métricas distintas para comparar los algoritmos de clasificación y los de detección de anomalías. Se obtienen los resultados de las métricas deseadas para cada uno de los modelos entrenados, y una vez se está en posesión de todas ellas se procede a comparar los modelos entre sí.

4.2 Elección del protocolo

Las opciones barajadas han sido Transmission Control Protocol (TCP) e Internet Control Message Protocol (ICMP). En un principio se pensaba usar las marcas de tiempo contenidas en las cabeceras de estos protocolos, pero esta idea fue descartada puesto que únicamente permitían obtener los tiempos en milisegundos. El objetivo era obtener los tiempos en nanosegundos por tanto, se enviaron los datos en el cuerpo del paquete que no tiene una limitación tan corta de espacio.

Con el fin de mantener la conexión persistente en toda la muestra se escogió el protocolo TCP, ya que una vez establecida la conexión se mantendrá hasta el final.

4.3 Obtención de datos

Para obtener los datos se usará una estructura cliente-servidor. Los dispositivos a analizar serán los que tomen el rol de servidores y el observador será el cliente.

Con esta idea en mente se crea un programa servidor que escuche a cualquier dirección IP en un determinado puerto y responda con una marca de tiempo en nanosegundos. Este programa se ejecutará en cada uno de los dispositivos bajo análisis.

A la hora de capturar los datos era necesario establecer el reloj interno sobre el que se tomarán los datos, ya que existen diferentes relojes dentro de un dispositivo.

- **system_clock** el cual contiene la hora actual [47]. Este reloj es modificable por los servicios que mantienen actualizada la hora del sistema como, por ejemplo, el servicio Network Time Protocol (NTP).

- `steady_clock` el cual contiene el número de ciclos de CPU desde el encendido del dispositivo [46].

Para los cometidos de este proyecto se usará el reloj `steady_clock`.

Una vez los dispositivos estén todos escuchando, el observador ejecutará un programa cliente que es el que se encargará de enviar los mensajes al servidor correspondiente. Este programa guarda una marca de tiempo al comienzo de la ejecución t_{start} , que será nuestro punto de referencia. Después mandará n mensajes equiespaciados en intervalos de 1 segundo.

En cada ejecución del bucle se obtendrá una marca de tiempo en el observador t_i , y una marca de tiempo del dispositivo t'_i . Con esto se consiguen tener varios datos:

- La marca de tiempo relativa a cada mensaje desde el inicio, $t_i - t_{start}$. Teóricamente debería de dar valores exactos, ya que se manda un mensaje cada segundo, pero existe cierto retraso.
- La marca de tiempo absoluta del observador t_i .
- La marca de tiempo absoluta del dispositivo t'_i .
- La desviación del reloj del dispositivo respecto al del observador, $t_i - t'_i$.

Un ejemplo de cómo se guardan estos datos se puede ver en la Tabla 4.1.

time	TSrock	TSrasp	offset	device
292	119238112796030	104592709716803	-14645403079227	192.168.1.111
1001191222	119239113986960	104593710167425	-14645403819535	192.168.1.111
2001485862	119240114281600	104594710453699	-14645403827901	192.168.1.111
⋮	⋮	⋮	⋮	⋮

Tabla 4.1: Ejemplo de los datos obtenidos de cada dispositivo

Este proceso se realizará para cada dispositivo tanto en una muestra secuencial, como en una muestra en paralelo. En la muestra secuencial se recibirán marcas de tiempo de un dispositivo durante 2 horas. Una vez transcurrido ese tiempo se comenzarán a recibir marcas de tiempo del siguiente dispositivo, y esta estructura se repite para cada dispositivo, obteniendo una muestra final de datos de unas 10 horas. En la muestra paralela por contra se recibirán marcas de tiempo de todos los dispositivos de forma simultánea, realizándose una captura global de 12 horas.

4.4 Análisis de los datos

En esta sección se estudiará el incremento de la desviación del reloj en cada una de las muestras, así como la desviación acumulada en cada punto.

4.4.1 Experimento 1: Muestra secuencial

En este primer experimento se ha tomado una muestra de 7200 segundos, es decir, 2 horas por dispositivo, lo que en total suman 10 horas de muestras.

En la Fig. 4.3 se muestra la desviación (offset) acumulada en cada dispositivo durante esas 2 horas.




Figura 4.3: Offset acumulado muestra secuencial

Como se puede ver hay 2 tipos de comportamiento. Los dispositivos 1, 2 y 3 se mantienen monótonos al comienzo para después incrementar mucho su desviación. Por contra los dispositivos 4 y 5 se mantienen sin grandes cambios en toda la muestra. Esto se puede ver más claramente en la Fig. 4.4.




Figura 4.4: Diferencias entre offsets de dispositivos

El objetivo final es obtener una forma de distinguir estadísticamente los datos, para ello se genera un gráfico que muestre entre que valores se mueven estos datos en cada dispositivo, en definitiva, se puede ver con un diagrama de cajas (Fig. 4.5). Se han eliminado los valores atípicos ya que a tan pequeña escala no dejan ver los verdaderos resultados.




Figura 4.5: Diagrama de cajas muestra secuencial

Este diagrama ilustra lo comentado anteriormente. Los dispositivos 4 y 5 son los que menos varían, esto se puede ver en que las cajas son pequeñas y la mediana está centrada entre los cuartiles (Q1 y Q3).

En los otros 3 dispositivos se observa como entre la mediana y el tercer cuartil hay más espacio que entre la mediana y el primer cuartil. Esto se debe a que tienen muchos incrementos grandes, por eso crecen tan bruscamente.

Con esto se tiene una idea de los dispositivos son distinguibles estadísticamente, lo que confirma que se podrá entrenar un modelo que los identifique.

4.4.2 Experimento 2: Muestra paralela

Para el segundo experimento se han capturado datos de todos los dispositivos simultáneamente durante un periodo de 43 200 segundos, es decir, 12 horas.

La Fig. 4.6 muestra la desviación acumulada en cada dispositivo en este periodo de tiempo. En este gráfico también se han marcado ciertos puntos en los que los dispositivos parecen “sincronizarse”. Con esto nos referimos a que alrededor de estas marcas de tiempo todos los dispositivos cambian de tendencia bruscamente y además parecen repetirse con cierta periodicidad. Las marcas de tiempo de este gráfico corresponden a los puntos {4000, 16 500, 29 000, 41 000} que están aproximadamente equidistantes (aproximadamente 12 000 segundos).

Esta “sincronización” entre dispositivos parece deberse a algún tipo de actualización del reloj interno del dispositivo observador (RockPro64) mediante algún demonio del sistema operativo. El principal demonio que se encarga de esta tarea es el servicio NTP, el cual fue desactivado para realizar estas pruebas.

Consultando otro diagrama de cajas con el incremento de la desviación en cada instante




Figura 4.6: Offset acumulado muestra paralela

(Fig. 4.7) se observa como todos los dispositivos están más a la par que en la muestra secuencial (Fig. 4.5). Aún así, siguen teniendo ciertas diferencias, con lo que se puede concluir que también son estadísticamente diferenciables.




Figura 4.7: Diagrama de cajas muestra paralela

4.4.3 Elección de la muestra de datos

Analizando los incrementos de la desviación en ambas muestras (Fig. 4.5 y 4.7) se puede ver que la muestra paralela tiene valores más parecidos a los esperados. Estos valores de

incremento de la desviación son más pequeños y más parecidos entre todos los dispositivos, es por ello que se entrenarán los algoritmos con los datos de la muestra paralela.

4.5 Preprocesamiento de los datos

En esta sección se realizará un preprocesamiento de los datos para su adecuación de cara al entrenamiento de los modelos de Machine Learning. se obtendrán diversas variables estadísticas de estos datos, y a continuación, se eliminarán las variables estadísticas que se encuentren correlacionadas.

Estas variables se obtendrán mediante el uso de una ventana deslizante de 1 minuto sobre el incremento de la desviación del reloj del dispositivo.

Una ventana deslizante es una forma de agrupar datos consecutivos mientras se recorre una colección. Un ejemplo de ventana deslizante se puede ver en la Fig. 4.8.

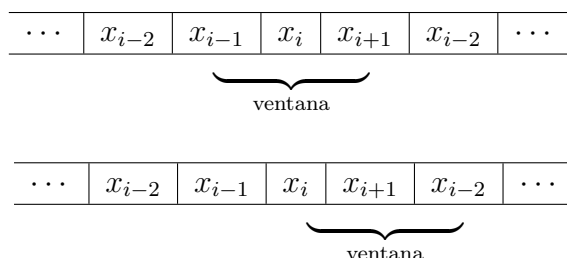


Figura 4.8: Ejemplo de una ventana deslizante

Las variables estadísticas que se obtendrán de los datos de la muestra paralela serán:

- Suma
- Media
- Mediana
- Moda
- Desviación típica
- Rango intercuartílico
- Curtosis
- Coeficiente de asimetría (skewness)
- Máximo
- Mínimo

4.5.1 Obtención de las variables estadísticas

En esta sección se generarán los datos estadísticos de la muestra paralela mediante la ventana deslizante, se obtienen los resultados que se pueden ver en la Tabla 4.2.

La decisión de utilizar datos estadísticos como entrada es obtener una mayor cantidad de datos para los algoritmos de Machine Learning. Dada la naturaleza de este estudio, sólo se está teniendo en cuenta un valor, la desviación del reloj de cada dispositivo.

Obteniendo estas variables estadísticas es posible generar vectores mucho mayores que aportarán mayor información a los distintos algoritmos a la hora del aprendizaje.


	Sum	Mean	Median	Mode	Std	IQR	Kurtosis	Skew	Max	Min	Device
1	-284.0	-4.733333333333333	-203.0	-10750.0	6531.321744049499	8739.5	-0.8026364427898236	0.266444555013173	12077.0	-10750.0	Disp. 1
2	-65895.0	-1098.25	106.5	-13344.0	3926.559099283938	2519.75	1.4605213340303709	-1.1040127142547507	7616.0	-13344.0	Disp. 2
3	96179.0	1602.9833333333333	815.0	-8136.0	5010.092595279735	6575.5	-0.39715065367509084	0.2484646585713819	12831.0	-8136.0	Disp. 3
4	109162.0	1819.3666666666666	2016.5	-10485.0	6159.084454763058	8290.5	-0.7264084617343212	-0.3858981208999922	11469.0	-10485.0	Disp. 4
5	-81317.0	-1355.2833333333333	-2127.0	-6378.0	3665.051390911538	2616.5	2.701193448053943	1.7089231615691112	10383.0	-6378.0	Disp. 5
6	19928.0	332.1333333333333	-147.0	-10750.0	6613.483928825726	10212.0	-0.8404647945245984	0.23473423365399895	12077.0	-10750.0	Disp. 1
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮

Tabla 4.2: Datos estadísticos muestra paralela

4.5.2 Reducción de la dimensionalidad

En esta sección se buscarán valores estadísticos correlacionados entre sí. En caso de existir una correlación mayor a 0.9, se eliminarán esas variables antes de entrenar los modelos, puesto que no aportan información y provocarán que el algoritmo tarde aún más tiempo en ser entrenado.

La correlación entre las variables estadísticas se puede ver en la Fig. 4.9. Se puede ver como suma, media y mediana son las variables más correlacionadas entre sí, por tanto serán eliminadas 2 de ellas (en este caso, media y mediana).



(a) Correlación entre las variables iniciales

(b) Correlación entre las variables finales

Figura 4.9: Correlación entre las variables estadísticas

4.6 Entrenamiento de los modelos

En esta sección se mostrará el proceso de entrenamiento de los distintos modelos.

Para realizar estos entrenamientos se ha usado la librería `scikit-learn` sobre el lenguaje de programación Python. Esta librería tiene clases que implementan los algoritmos vistos anteriormente en la sección de *Estado del arte*. Las clases que corresponden a cada modelo son las que se ven en la Tabla 4.3.

Algoritmo	Implementación	Tipo de aprendizaje	Objetivo
Árboles de decisión	<code>DecisionTreeClassifier</code> [36]	Supervisado	Clasificación
Random Forest	<code>RandomForestClassifier</code> [45]	Supervisado	Clasificación
MLP	<code>MLPClassifier</code> [43]	Supervisado	Clasificación
Naive Bayes	<code>GaussianNB</code> [37]	Supervisado	Clasificación
KNN	<code>KNeighborsClassifier</code> [40]	Supervisado	Clasificación
SVM	<code>LinearSVC</code> [41]	Supervisado	Clasificación
Isolation Forest	<code>IsolationForest</code> [39]	No supervisado	Detección de anomalías
Local Outlier Factor	<code>LocalOutlierFactor</code> [42]	No supervisado	Detección de anomalías
OneClass-SVM	<code>OneClassSVM</code> [44]	No supervisado	Detección de anomalías

Tabla 4.3: Equivalencia entre algoritmo e implementación

4.6.1 Entrenamiento de los algoritmos de clasificación

A la hora de entrenar algoritmos de Machine Learning, lo primero que hay que hacer es ajustar sus hiperparámetros. Los hiperparámetros de un modelo son parámetros del mismo que se pueden modificar para que este se adapte mejor a los datos con los que se está trabajando o para cambiar la forma en la que aprende este modelo también para adaptarse a estos datos.

Para ajustar los hiperparámetros no se usa la completitud de los datos, se usa un modelo de entrenamiento/validación/test. Los datos se han dividido en un conjunto de entrenamiento y otro de test, 70 % para entrenamiento y 30 % para test, lo habitual es tener en torno a una tercera parte de los datos para entrenamiento y el resto para test. Este proceso (Fig. 4.10) se realiza con el objetivo de comprobar la capacidad de generalización del modelo con datos que no haya visto nunca.




Figura 4.10: Particiones de los datos

Para particionar los datos se tomarán muestras aleatorias, pero ordenadas para mantener la correlación temporal de los datos. Por ejemplo, ante el conjunto de datos x_1, \dots, x_{20} , una muestra aleatoria podría ser $x_{15}, x_8, x_3, x_{17}, x_5, x_{12}$ pero si estos datos presentan una correlación temporal, como es el caso de este trabajo, esta se pierde. Por tanto, los datos

han de ser devueltos a su orden natural $x_3, x_5, x_8, x_{12}, x_{15}, x_{17}$.

El conjunto de entrenamiento se usará únicamente con el modelo final y con los hiperparámetros ya ajustados, puesto que contiene una gran cantidad de datos. Para ajustar los hiperparámetros de cada modelo y comparar los modelos entre sí se usará un conjunto reducido de este, un 35 % de los datos de entrenamiento.

Este subconjunto de los datos de entrenamiento también será dividido en un conjunto de entrenamiento/test, aunque en este caso el conjunto test recibirá el nombre de conjunto de validación. Se entrenarán los distintos algoritmos con estos conjuntos con el fin de ajustar los hiperparámetros y decidir el mejor entre todos ellos.

Para comprobar qué hiperparámetros son los que mejor se ajustan a los datos, se usará la función `GridSearchCV` [38] que permite que dados un algoritmo y un conjunto de valores para los hiperparámetros probar todas las combinaciones y obtener así un accuracy de cada uno, con lo que se pueden comparar y filtrar únicamente a los mejores. Esta función permite usar la validación cruzada. La validación cruzada

A continuación se mostrará un ejemplo del proceso de ajustar los hiperparámetros de un modelo, en este caso se usará el algoritmo de Random Forest sobre los datos la muestra paralela. Los hiperparámetros que se han decidido ajustar son:

- **criterion:** función que mide la pureza de los nodos hijos.
- **max_features:** número de características que se tienen en cuenta para realizar la división de un nodo.
- **n_estimators:** número de árboles de decisión que participan en el algoritmo.

Para evitar que una rama entre en un bucle infinito debido a que no es capaz de dividir correctamente los nodos se ha fijado la profundidad máxima de cada rama (hiperparámetro **max_depth**) a un valor de 1000.

Hablando en primer lugar sobre los hiperparámetros **criterion** y **max_features** (Fig. 4.11a) se puede ver que en promedio el mejor valor de **criterion** es **gini**. Este parámetro será fijado y, a continuación, se comprobarán todos los pares de valores que generan los hiperparámetros **max_features** y **n_estimators** (Fig. 4.11b).




Figura 4.11: Comparativa hiperparámetros Random Forest

Los mejores valores obtenidos son `criterion = gini`, `n_estimators = 100` y `max_features = sqrt`. Con estos hiperparámetros se entrenará un modelo sobre el conjunto de entrenamiento menor y después se realizará una predicción con el conjunto de validación.

4.6.2 Entrenamiento de los algoritmos de detección de anomalías

A la hora de entrenar algoritmos de aprendizaje no supervisado, se realiza un proceso de ajuste similar al visto en la sección anterior. Sin embargo, existe una diferencia y esa son los datos de entrada del algoritmo.

Mientras que con los algoritmos de clasificación se realizaba una división únicamente teniendo en cuenta el tamaño del conjunto de los datos, en este caso se entrenará cada algoritmo únicamente con el 80 % de los datos de un dispositivo. Posteriormente, se usarán el 20 % de los datos de ese dispositivo para obtener un valor de True Positive Rate (TPR) o *Recall* y el 20 % de los datos del resto de dispositivos para obtener un valor de True Negative Rate (TNR). Este proceso se realiza con el fin de comprobar si el modelo es capaz de detectar como datos correctos aquellos provenientes de su mismo dispositivo y detectar como datos anómalos los del resto de dispositivos. Este división se puede ver de forma gráfica en la Fig. 4.12.

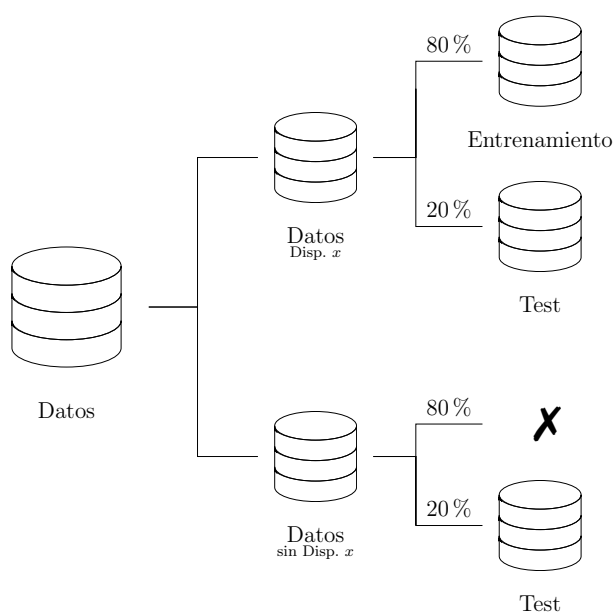


Figura 4.12: Particiones de los datos

Resultados

Una vez entrenados todos los algoritmos con sus mejores hiperparámetros, se obtienen los resultados de los modelos de clasificación, que se pueden ver en la Fig. 5.1; y también los resultados que aportan los modelos de detección de anomalías, presentados en la Tabla 5.3.

Para analizar todos estos modelos se hará uso de diversas métricas, como las que se presentan entre las fórmulas 5.1 y 5.4. Para obtener estas métricas es necesario hacer uso de matrices de confusión.

Una matriz de confusión es una tabla que evalúa los resultados de un modelo Machine Learning orientado a la clasificación. En este tipo de tablas se enfrentan valores bien predichos y mal predichos observando las etiquetas reales y las predichas por los datos. Un ejemplo de matriz de confusión se puede ver a continuación en la Tabla 5.1. Con este tipo de herramientas es sencillo ver los aciertos y fallos de un modelo. Esta herramienta también se puede generalizar a clasificación multiclase, que ha sido el uso en este trabajo.

Con una matriz de confusión es posible obtener las distintas métricas que sirven para comparar los modelos de Machine Learning como Accuracy, Recall, True Negative Rate (TNR), f -score.

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN} \quad (5.1) \quad f - score = \frac{2 \cdot TP}{2 \cdot TP + FP + FN} \quad (5.3)$$

$$Recall = \frac{TP}{TP + FN} \quad (5.2) \quad TNR = \frac{TN}{TN + FP} \quad (5.4)$$

		Valor predicho	
		Sí	No
Valor real	Sí	Verdadero positivo (TP)	Falso positivo (FP)
	No	Falso negativo (FN)	Verdadero negativo (TN)

Tabla 5.1: Ejemplo de matriz de confusión

Analizando en primer lugar los modelos de clasificación, se puede ver en la figura anteriormente mencionada, Fig. 5.1, que los modelos que presentan mejores resultados son los que se basan en árboles de decisión, que son el propio algoritmo de árboles de decisión y random forest. Otra forma de ver estos resultados es mediante las matrices de confusión que genera cada algoritmo.




Figura 5.1: Comparativa de resultados entre modelos de clasificación

Es fácil ver en la Fig. 5.2 que los modelos basados en árboles aciertan prácticamente en la totalidad de las ocasiones, en particular, el algoritmo de Random Forest es el que mejores resultados consigue con aproximadamente 99.5 % en todas las métricas analizadas, seguido de cerca por Árboles de Decisión con aproximadamente 97.6 % en todas las métricas.

Desde el punto de vista de los modelos de detección de anomalías, no se han obtenido valores de las métricas tan altas como en los algoritmos de clasificación vistos anteriormente. Se pone como ejemplo el cálculo de las métricas de Recall y TNR que se hace en función de las dos matrices de confusión, Tabla 5.2, que genera el par $\langle \text{Dispositivo}, \text{Algoritmo} \rangle$.

En la evaluación de detectar como valores correctos los de su propio dispositivo se obtiene un Recall, usando la Fórmula 5.2, de 95.12 %. Este valor es obtenido mediante la matriz de confusión mostrada en la Tabla 5.2a. Por contra, en la tarea de detectar como valores anómalos los provenientes del resto de dispositivos (Tabla 5.2b), no obtiene un valor tan elevado, tan solo un 10.36 % de TNR (Fórmula 5.4).

Valor real	Valor predicho		Valor real	Valor predicho	
	Sí	No		Sí	No
	Sí	No		Sí	No
	8034	412		0	0
	0	0		29027	3354

(a) 20 % de los datos del Disp. 1

(b) 20 % de los datos de todos excepto el Disp. 1

Tabla 5.2: Matrices de confusión del Disp. 1 con el modelo de Isolation Forest

El resto de valores de la tabla de resultados (Tabla 5.3) son generados mediante el mismo procedimiento.

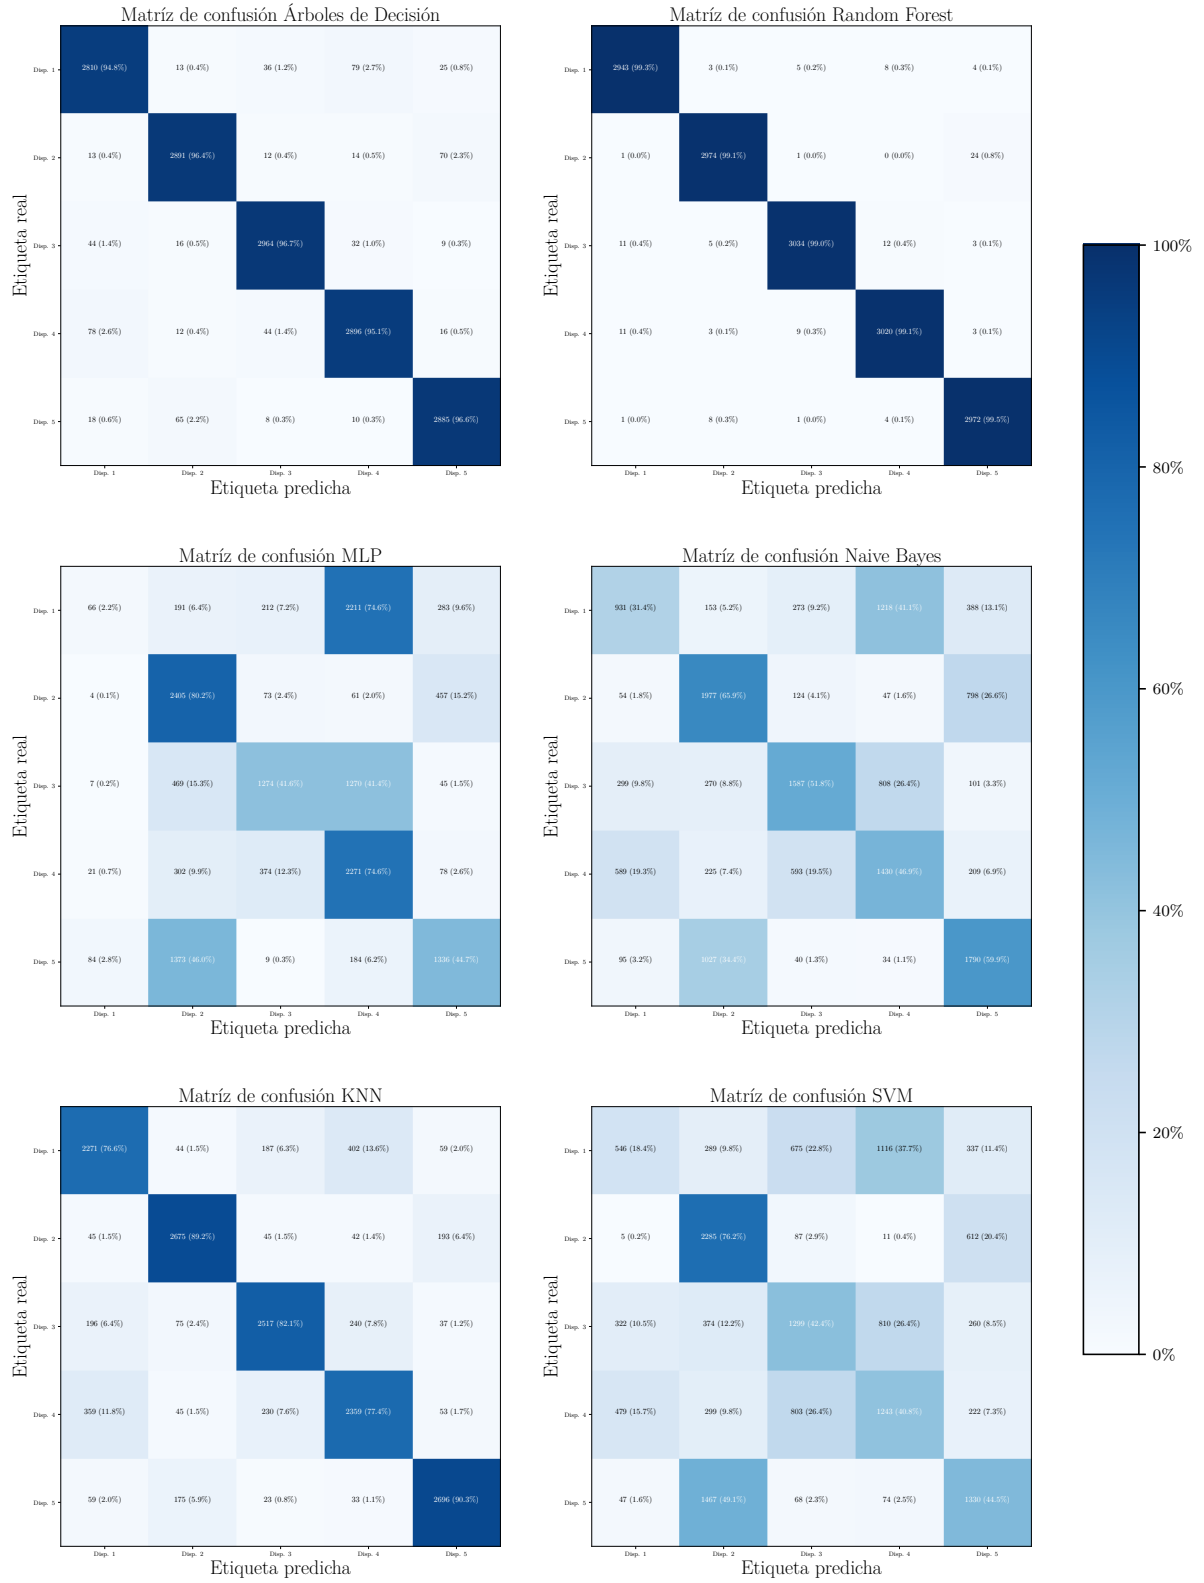


Figura 5.2: Matrices de confusión con datos de la muestra paralela

	Isolation Forest		Local Outlier Factor		OneClass-SVM	
	<i>Recall</i>	<i>TNR</i>	<i>Recall</i>	<i>TNR</i>	<i>Recall</i>	<i>TNR</i>
Disp. 1	95.12 %	10.36 %	98.99 %	10.68 %	49.48 %	58.24 %
Disp. 2	94.98 %	28.87 %	98.45 %	57.74 %	50.90 %	70.36 %
Disp. 3	94.80 %	13.90 %	98.73 %	13.64 %	49.84 %	52.65 %
Disp. 4	95.80 %	16.61 %	98.88 %	8.74 %	50.54 %	64.66 %
Disp. 5	94.89 %	46.99 %	98.63 %	77.98 %	49.53 %	94.59 %

Tabla 5.3: Resultados de los modelos de detección de anomalías

Atendiendo al resto de valores de los modelos de detección de anomalías, se puede observar en la Tabla 5.3 que ninguno de los modelos entrenados es capaz de identificar de una forma solvente a los distintos dispositivos. El mejor entre ellos es OneClass-SVM, pero no es capaz de obtener resultados tan elevados en comparación con los modelos de clasificación. Sin embargo, se observa que tanto el Disp. 2 como el Disp. 5 obtienen, en general, resultados mejores. Atendiendo a la Fig. 4.7 se puede ver que estos dispositivos son los que presentan una menor variabilidad en el incremento del desfase de sus relojes.

Una vez comparados todos los modelos que han sido creados para este trabajo, se llega a la conclusión de que el mejor entre ellos es el algoritmo de clasificación Random Forest. Por ello se ha generado un modelo final con los hiperparámetros ajustados anteriormente y con la totalidad de los datos de entrenamiento. Los resultados obtenidos se pueden ver en la matriz de confusión resultante (Fig. 5.3). Con estos resultados se tiene un valor final de Accuracy de 99.38 %, de Recall de 99.39 % y de f -score de 99.38 %.




Figura 5.3: Matriz de confusión del modelo final

CAPÍTULO 6

Conclusiones y vías futuras

En este proyecto se ha diseñado un modelo capaz de clasificar dispositivos con los que se ha establecido una comunicación en base a pequeñas diferencias en la fabricación de los componentes, que alteran el tiempo que tardan en ejecutarse ciertas tarea.

En la primera parte del proyecto se ha visto que para obtener la precisión en los tiempos deseada, ha sido necesario el uso del protocolo TCP y el envío de las marcas de tiempo en el cuerpo del paquete.

Durante el desarrollo de esta parte de la investigación se apreció que el reloj interno es susceptible de ser alterado por procesos externos con el cometido de que esté sincronizado en todo momento con el resto de los dispositivos (protocolo NTP). Por este motivo este servicio tuvo que ser desactivado antes de realizar ninguna recolección de datos, pues los diferencias entre tiempos no serían las propias de cada dispositivo.

Una vez desactivado el servicio, aún se obtenían datos que no eran correctos debido a que se estaba usando un reloj del sistema que podía ser modificado. Este reloj fue cambiado por un reloj que no fuera modificable por procesos externos (`steady_clock`) y con eso los datos fueron más precisos.

Se realizaron capturas tanto en secuencial como en paralelo de la desviación de los relojes de los dispositivos, de las cuales se obtuvieron sus incrementos en cada momento. Con estos incrementos y una ventana deslizante de 1 minuto se obtuvieron las variables estadísticas que servirían para entrenar los modelos. Se analizaron estas variables y se eliminaron aquellas que presentaban correlación.

Se entrenaron modelos tanto de clasificación como de detección de anomalías con las variables mencionadas anteriormente y, posteriormente, se compararon entre sí para decidir cual es el modelo que mejor se ajustaba a los datos, eligiéndose el algoritmo de clasificación Random Forest como el mejor.

Por último, se entrenó el algoritmo elegido, Random Forest, con los datos de la muestra paralela y los hiperparámetros que se consideraron mejores cuando se realizó el entrenamiento con los conjuntos de entrenamiento/validación. De este modelo se obtuvieron unos resultados

finales de 99.38 % en el valor de Accuracy, de 99.39 % en el valor de Recall y de 99.38 % en el valor de f -score.

Comparando este trabajo con aquellos que han sido analizados en el capítulo de *Estado del arte*, se llega a la conclusión de que se ha creado un sistema capaz de identificar dispositivos con una precisión similar a la de los revisados. Sin embargo, estos datos han sido obtenidos en un ambiente muy controlado y que no es representativo de un escenario real. También han existido problemas como el mencionado con el servicio NTP, que puede haber influido en los resultados finales.

Una de las posibles vías futuras de este trabajo sería el desarrollo de un modelo a tiempo real de este sistema. Para este cometido se debería tener una copia local de las huellas que generan ciertos dispositivos para poder compararlos con los que estamos recibiendo en ese momento y así comprobar si se trata de un atacante.

Para realizar este sistema a tiempo real también habría que crear mecanismos que permitan al sistema actualizarse con nuevos datos, y con ello generar nuevas huellas para los dispositivos. También habría que modificar los modelos de Machine Learning debido a que para que el sistema funcione a tiempo real, estos deberían actualizarse.

Bibliografía

- [1] M. Abadi *et al.*, *TensorFlow: Large-scale machine learning on heterogeneous systems*, Software available from tensorflow.org, 2015. [Online]. Available: <https://www.tensorflow.org/>.
- [2] A. Aksoy and M. H. Gunes, “Automated iot device identification using network traffic”, in *ICC 2019 - 2019 IEEE International Conference on Communications (ICC)*, 2019, pp. 1–7.
- [3] A. Al-Omary, A. Othman, H. M. AlSabbagh, and H. Al-Rizzo, “Survey of hardware-based security support for iot/cps systems”, *KnE Engineering*, pp. 52–70, 2018.
- [4] I. Bisio, C. Garibotto, F. Lavagetto, A. Sciarrone, and S. Zappatore, “Unauthorized amateur uav detection based on wifi statistical fingerprint analysis”, *IEEE Communications Magazine*, vol. 56, no. 4, pp. 106–111, 2018, ISSN: 1558-1896.
- [5] D. A. Borman, R. T. Braden, and V. Jacobson, “TCP Extensions for High Performance”, Tech. Rep. 1323, May 1992, 37 pp. [Online]. Available: <https://rfc-editor.org/rfc/rfc1323.txt>.
- [6] L. Breiman, “Random forests”, *Machine learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [7] J. Cervantes, F. Garcia-Lamont, L. Rodríguez-Mazahua, and A. Lopez, “A comprehensive survey on support vector machine classification: Applications, challenges and trends”, *Neurocomputing*, vol. 408, pp. 189–215, 2020, ISSN: 0925-2312. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0925231220307153>.
- [8] Z. Cheng, C. Zou, and J. Dong, “Outlier detection using isolation forest and local outlier factor”, in *Proceedings of the Conference on Research in Adaptive and Convergent Systems*, ser. RACS '19, Chongqing, China: Association for Computing Machinery, 2019, 161–168, ISBN: 9781450368438. [Online]. Available: <https://doi.org/10.1145/3338840.3355641>.
- [9] W. Commons. “File:knnclassification”. (2010), [Online]. Available: <https://commons.wikimedia.org/wiki/File:KnnClassification.svg>.
- [10] W. Commons. “Svm separating hyperplanes (svg)”. (2012), [Online]. Available: [https://commons.wikimedia.org/wiki/File:Svm_separating_hyperplanes_\(SVG\).svg](https://commons.wikimedia.org/wiki/File:Svm_separating_hyperplanes_(SVG).svg).
- [11] L. C. C. Desmond, C. C. Yuan, T. C. Pheng, and R. S. Lee, “Identifying unique devices through wireless fingerprinting”, in *Proceedings of the First ACM Conference on Wireless Network Security*, ser. WiSec '08, Alexandria, VA, USA: Association for Computing Machinery, 2008, pp. 46–55, ISBN: 9781595938145. [Online]. Available: <https://doi.org/10.1145/1352533.1352542>.

-
- [12] M. U. Farooq, M. Waseem, S. Mazhar, A. Khairi, and T. Kamal, "A review on internet of things (iot)", *International journal of computer applications*, vol. 113, no. 1, pp. 1–7,
 - [13] D. Gislason, *Zigbee Wireless Networking*, Pap/Onl. USA: Newnes, 2008, ISBN: 978-0-7506-8597-9.
 - [14] P. Gokhale, O. Bhat, and S. Bhat, "Introduction to iot", *International Advanced Research Journal in Science, Engineering and Technology*, vol. 5, no. 1, pp. 41–44, 2018.
 - [15] M. Hall, E. Frank, G. Holmes, B. Pfahringer, P. Reutemann, and I. H. Witten, "The weka data mining software: An update", *SIGKDD Explor. Newsl.*, vol. 11, no. 1, pp. 10–18, 2009, ISSN: 1931-0145. [Online]. Available: <https://doi.org/10.1145/1656274.1656278>.
 - [16] S. A. Hamad, W. E. Zhang, Q. Z. Sheng, and S. Nepal, "Iot device identification via network-flow based fingerprinting and learning", in *2019 18th IEEE International Conference On Trust, Security And Privacy In Computing And Communications/13th IEEE International Conference On Big Data Science And Engineering (TrustCom/Big-DataSE)*, IEEE, 2019, pp. 103–111.
 - [17] J. Hatwell, M. M. Gaber, and R. M. A. Azad, "Chirps: Explaining random forest classification", *Artificial Intelligence Review*, vol. 53, pp. 5747–5788, 2020.
 - [18] N. Hoque, D. K. Bhattacharyya, and J. K. Kalita, "Botnet in ddos attacks: Trends and challenges", *IEEE Communications Surveys & Tutorials*, vol. 17, no. 4, pp. 2242–2270, 2015, ISSN: 1553-877X.
 - [19] "Isolationforest example", [Online]. Available: https://scikit-learn.org/stable/auto_examples/ensemble/plot_isolation_forest.html#sphx-glr-auto-example-s-ensemble-plot-isolation-forest-py.
 - [20] H. Jafari, O. Omotere, D. Adesina, H.-H. Wu, and L. Qian, "Iot devices fingerprinting using deep learning", in *MILCOM 2018 - 2018 IEEE Military Communications Conference (MILCOM)*, 2018, pp. 1–9.
 - [21] F. Lanze, A. Panchenko, B. Braatz, and A. Zinnen, "Clock skew based remote device fingerprinting demystified", in *2012 IEEE Global Communications Conference (GLOBECOM)*, 2012, pp. 813–819.
 - [22] K.-L. Li, H.-K. Huang, S.-F. Tian, and W. Xu, "Improving one-class svm for anomaly detection", in *Proceedings of the 2003 International Conference on Machine Learning and Cybernetics (IEEE Cat. No.03EX693)*, vol. 5, 2003, 3077–3081 Vol.5.
 - [23] F. T. Liu, K. M. Ting, and Z.-H. Zhou, "Isolation forest", in *2008 Eighth IEEE International Conference on Data Mining*, 2008, pp. 413–422.
 - [24] Y. Meidan *et al.*, "Profiliot: A machine learning approach for iot device identification based on network traffic analysis", in *Proceedings of the Symposium on Applied Computing*, ser. SAC '17, Marrakech, Morocco: Association for Computing Machinery, 2017, pp. 506–509, ISBN: 9781450344869. [Online]. Available: <https://doi.org/10.1145/3019612.3019878>.
 - [25] R. van der Meulen, *8.4 billion connected things will be in use 2017 | gartner*, <https://www.gartner.com/en/newsroom/press-releases/2017-02-07-gartner-says-8-billion-connected-things-will-be-in-use-in-2017-up-31-percent-from-2016>, 2017.
 - [26] M. Miettinen, S. Marchal, I. Hafeez, N. Asokan, A.-R. Sadeghi, and S. Tarkoma, "Iot sentinel: Automated device-type identification for security enforcement in iot", *2017*
-

-
- IEEE 37th International Conference on Distributed Computing Systems (ICDCS)*, 2017. [Online]. Available: <http://dx.doi.org/10.1109/ICDCS.2017.283>.
- [27] B. Miller and D. Rowe, "A survey scada of and critical infrastructure incidents", in *Proceedings of the 1st Annual Conference on Research in Information Technology*, ser. RIIT '12, Calgary, Alberta, Canada: Association for Computing Machinery, 2012, 51–56, ISBN: 9781450316439. [Online]. Available: <https://doi.org/10.1145/2380790.2380805>.
- [28] K. P. Murphy *et al.*, "Naive bayes classifiers", *University of British Columbia*, vol. 18, no. 60, pp. 1–8, 2006.
- [29] F. Murtagh, "Multilayer perceptrons for classification and regression", *Neurocomputing*, vol. 2, no. 5, pp. 183–197, 1991, ISSN: 0925-2312. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/0925231291900235>.
- [30] A. Nicholson, S. Webber, S. Dyer, T. Patel, and H. Janicke, "Scada security in the light of cyber-warfare", *Computers & Security*, vol. 31, no. 4, pp. 418–436, 2012, ISSN: 0167-4048. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0167404812000429>.
- [31] M. R. Nosouhi, K. Sood, M. Grobler, and R. Doss, *IEEE Transactions on Information Forensics and Security*, ISSN: 1556-6021.
- [32] "One-class svm with non-linear kernel (rbf)", [Online]. Available: https://scikit-learn.org/stable/auto_examples/svm/plot_oneclass.html#sphx-glr-auto-examples-svm-plot-oneclass-py.
- [33] P. Oser, F. Kargl, and S. Lüders, "Identifying devices of the internet of things using machine learning on clock characteristics", in *Security, Privacy, and Anonymity in Computation, Communication, and Storage*, G. Wang, J. Chen, and L. T. Yang, Eds., Cham: Springer International Publishing, 2018, pp. 417–427, ISBN: 978-3-030-05345-1.
- [34] K. Shafique, B. A. Khawaja, F. Sabir, S. Qazi, and M. Mustaqim, "Internet of things (iot) for next-generation smart systems: A review of current challenges, future trends and prospects for emerging 5g-iot scenarios", *IEEE Access*, vol. 8, pp. 23 022–23 040, 2020, ISSN: 2169-3536.
- [35] K. Taunk, S. De, S. Verma, and A. Swetapadma, "A brief review of nearest neighbor algorithm for learning and classification", in *2019 International Conference on Intelligent Computing and Control Systems (ICCS)*, 2019, pp. 1255–1260.
- [36] "DecisionTreeClassifier", [Online]. Available: <https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeClassifier.html#sklearn.tree.DecisionTreeClassifier>.
- [37] "GaussianNB", [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.naive_bayes.GaussianNB.html#sklearn.naive_bayes.GaussianNB.
- [38] "GridSearchCV", [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html.
- [39] "IsolationForest", [Online]. Available: <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.IsolationForest.html#sklearn.ensemble.IsolationForest>.
- [40] "KNeighborsClassifier", [Online]. Available: <https://scikit-learn.org/stable/modules/generated/sklearn.neighbors.KNeighborsClassifier.html>.
-

-
- [41] “LinearSVC”, [Online]. Available: <https://scikit-learn.org/stable/modules/generated/sklearn.svm.LinearSVC.html>.
 - [42] “LocalOutlierFactor”, [Online]. Available: <https://scikit-learn.org/stable/modules/generated/sklearn.neighbors.LocalOutlierFactor.html#sklearn.neighbors.LocalOutlierFactor>.
 - [43] “MLPClassifier”, [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPClassifier.html#sklearn.neural_network.MLPClassifier.
 - [44] “OneClass-SVM”, [Online]. Available: <https://scikit-learn.org/stable/modules/generated/sklearn.svm.OneClassSVM.html#sklearn.svm.OneClassSVM>.
 - [45] “RandomForestClassifier”, [Online]. Available: <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html#sklearn.ensemble.RandomForestClassifier>.
 - [46] “std::chrono::steady_clock”, [Online]. Available: https://en.cppreference.com/w/cpp/chrono/steady_clock.
 - [47] “std::chrono::system_clock”, [Online]. Available: https://en.cppreference.com/w/cpp/chrono/system_clock.
 - [48] “The "only" coke machine on the internet”. (1982), [Online]. Available: https://www.cs.cmu.edu/~coke/history_long.txt.
 - [49] C. Veenman, M. Reinders, and E. Backer, “A maximum variance cluster algorithm”, *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 24, no. 9, pp. 1273–1280, 2002.
 - [50] N. Wang, L. Jiao, P. Wang, M. Dabaghchian, and K. Zeng, “Efficient identity spoofing attack detection for iot in mm-wave and massive mimo 5g communication”, in *2018 IEEE Global Communications Conference (GLOBECOM)*, 2018, pp. 1–6.
 - [51] I. Yaqoob *et al.*, “Internet of things architecture: Recent advances, taxonomy, requirements, and open challenges”, *IEEE Wireless Communications*, vol. 24, no. 3, pp. 10–16, 2017, ISSN: 1558-0687.
 - [52] N. Yousefnezhad, A. Malhi, and K. Främling, “Security in product lifecycle of iot devices: A survey”, *Journal of Network and Computer Applications*, vol. 171, p. 102779, 2020, ISSN: 1084-8045. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1084804520302538>.

Acrónimos

CERN Conseil Européen pour la Recherche Nucléaire. 13

DDoS Distributed Denegation of Service. 1

FNMT Fábrica Nacional de Moneda y Timbre. 2

GBM Gradient Boost Machine. 16, 17

ICMP Internet Control Message Protocol. 23

IoT Internet of Things. iii, iv, 1, 2, 5, 16, 17

KNN K Nearest Neighbours. ii, v, 14

LDA Linear Discriminant Analysis. 14

LOF Local Outlier Factor. ii, v, 11

MLP Multi Layer Perceptron. ii, v, 13

NTP Network Time Protocol. iv, 16, 22, 23

OC-SVM OneClass-SVM. ii, v, 12

QoS Quality of Service. iii, 6

RFID Radio Frequency Identification. 5

SVM Support Vector Machines. ii, v, 12–14

TCP Transmission Control Protocol. 13, 16, 17, 23

TNR True Negative Rate. 32

TPR True Positive Rate. 32

TTL Time To Live. 14

WEKA Waikato Environment for Knowledge Analysis. 15